动态对话记忆管理：M4 中期报告

Milestone 4 • 需求规格、系统设计、实现与初步测试

队名：在阴雨天游泳 Team ID：3 日期：2026-10-23

成员：莫远序、黎志丽、卓新烨、田亦洁

版本：v0.6，待成员复核；实现基准：main@ffb2657。

1 需求规格

本项目开发基于 LoCoMo 长期对话的动态记忆 Web 应用。系统从原始对话提取结构化 Memory，检索与问题相关的历史，再结合时间及状态关系选择有效证据并回答。本阶段主要呈现需求规格、系统设计、已实现功能与初步测试。〔1〕 〔2〕

用户任务	核心需求与可观察结果	验收方法	当前实现与验证状态
开发者导入、构建或恢复记忆	原子记忆保留人物、时间、性质和来源；失败可重试，完整后发布	输入合法 / 非法数据；模拟中断，检查来源、重复产物与版本切换	已实现；工程和浏览器已有验证，真实 conv-26 Build 已发布；抽取语义未逐条独立核验
复核者检查历史与状态	旧记忆保留，关系有端点、理由与证据，当前状态可重算	对照原文检查阶段推进、替代、冲突和未知；交叉查询当前与历史	已实现；合成边界已检，10 个真实案例已有作者审阅，未独立复核
评测者查询当前或过去	混合召回、扩展历史、选择有效证据，返回答案及解释	检查初始 / 扩展 / 有效集合、截止时间、回答和引用	已实现；20 题五策略和 40 题检索已运行；留出集与独立动态准确率未评
用户补查证据不足的问题	有界原文补查；冲突与不足分别说明，不改写记忆库	检查补查来源、预算、支持保留、失败回退及 Trace	已实现；QA148 观察到补查收益，预算回退有记录；总体质量收益未证实
用户查看证据并导出 JSON	Web 展示答案、历史、Trace 与原文；导出同一完整版本	展开引用、切换已有结果并下载，检查版本一致及无新生成	已实现；工程、浏览器及真实结果回放已有验证；展示环境本轮尚未复测
评测者复现并比较策略	固定样本、版本与配置，记录分数、失败和用量	重算逐题 F1 / Recall，核对请求及实际执行策略、重试与 token	已实现；conv-26 展示完成；跨对话评测与留出集测试尚未完成

仅原始 conversation 进入构建，QA 与辅助标注隔离。开发对话为 conv-26/30/41/42，本地留出为 conv-43/44；当前展示仅使用 conv-26。〔2〕 〔3〕

2 系统设计

应用采用 Streamlit → FastAPI → 业务模块 → SQLite / 检索索引的调用路径。页面只负责交互和展示，持久化、校验及状态变更由后端统一处理。SQLite 适合课程数据规模，生成模型和 Embedding 通过适配层接入，无须独立图数据库或向量数据库。〔2〕

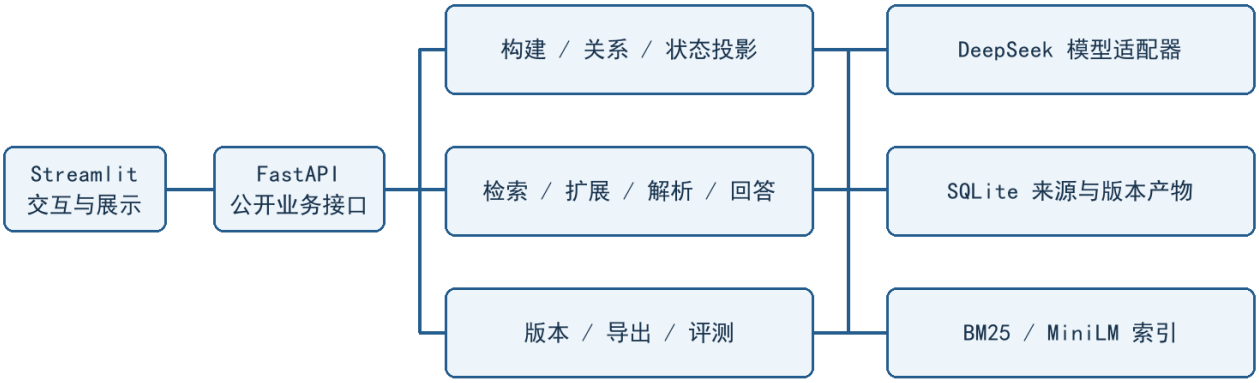


图 1 模块架构。DeepSeek 完成抽取、关系判断、查询分析、证据解析与回答；MiniLM 生成本地向量，BM25 与 RRF 实现混合召回。

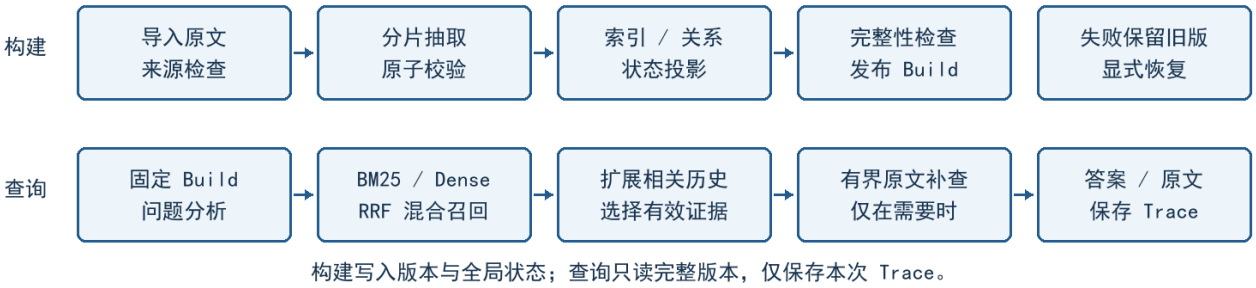


图 2 两条路径共享完整 Build。构建检查通过才发布并整体切换；失败保留旧完整版本。查询固定同一版本，原始问题始终参与召回，分析失败退回原问题。原文补查只读且有界，不能产生新 Memory。〔4〕

一条 Memory 表达一项可独立核查的陈述，分别保存内容、人物、状态维度、时间、性质及来源。同轮可产生多条记忆，多轮也可共同支持一条；事实、计划、否定与不确定陈述分开。state_key 标识对话、实体和维度，状态值另存，同键不自动互斥。

使用 MemoryRelation 保存端点、标签、理由和原文证据，区分 RETAIN、UPDATE、SUPERSEDE、CONFLICT 与未确定。保留旧记忆，才能回答过去时点的问题、追溯演化并复核判断；新证据替代当前取值，也不抹除旧事实的历史意义。时间较新不能单独证明替代。

有效证据：召回只说明相关；解析还要按问题的人物、维度和时间选择适用记忆。旧、新记录可能同时有效，也可能因计划尚未发生或时间不符被排除。“现在”指对话最后会话的已知截止时间，未知日期不强行精确化。

查询不修改全局状态：历史提问和本次补判是问题范围内的选择，不代表现实发生更新。结论只保存于 QueryTrace；全局关系与可重算 Current State 由构建 / 显式重建维护，避免答案依赖提问顺序。〔2〕〔4〕

3 已实现功能：一次真实职业探索问答

案例 state-01，conv-26，Dynamic；问题：“As of the end of the conversation, what is known about Caroline’s career exploration?”（截至对话结束，Caroline 的职业探索有何进展？）

历史阶段	抽取记忆及性质	可定位原文
D1:9，2023-05-08	计划了解职业选项；plan；Memory ab5f9130…	“Gonna continue my edu and check out career options”
D7:7，2023-07-12	已开始探索咨询与心理健康职业；fact；Memory 376676a7…	“I started looking into counseling and mental health career options”

关系判断：同一职业探索过程从计划推进到实际行动，记录 UPDATE（关系 581985a7…），而非把旧计划判为错误或删除。有效证据：旧、新端点均进入本次有效集合；工作坊是已发生事件，继续教育仍是计划，不推断已取得职业资格。

答案节选：“Caroline is exploring a career in counseling and mental health …”；回答还说明其兴趣、工作坊及继续教育计划，引用包含 D1:9、D7:7 等原文。历史、关系、有效集合和完整答案均可通过本案例机器记录复核，完整原文与解析见证据包。



图 3 职业探索问答页面局部：保存 Trace 的只读回放，显示证据支持状态和答案；完整截图。

Trace：fb0b30cf8e254441be9d4830319b1634。演示视频：未录制，文件名与案例时间段待补。运行入口为 FastAPI＋Streamlit（WSL、Python 3.12、uv），启动命令见〔4〕。

4 初步测试与真实展示结果

展示验证：2026-10-21，conv-26 开发对话，完整 Build 5c7699dd…（272 条 Memory、4,902 条关系），配置和指纹见 plan.json。生成模型为 deepseek-flash，MiniLM revision 与各阶段设置固定，复用同一 Build。〔3〕 〔5〕

工程验证：已有非 live 回归 405 passed、4 skipped，覆盖导入、恢复、版本、检索、查询和导出；展示前相关测试 24 passed，真实 MiniLM 检查 3 passed。受控浏览器覆盖当前 / 历史 / 冲突 / 不足及评测页面，退出 0；真实 Trace 回放 5 项通过，页面和控制台错误为 0。〔5〕 〔6〕

问答样本按五个类别各预选 4 题，同题运行五策略，共 100 项，各策略均成功 20/20。F1 按既有官方类别分支计算，仅汇总类别 1–4 的 16 题；类别 5 的 4 题在表后单列。

策略	类别 1–4 F1	输入 tokens / 20 题	输出 tokens / 20 题
Full Text（完整原始对话）	0.3490	1,270,393	2,558
Vector RAG	0.4911	159,789	3,567
Hybrid（无有效证据解析）	0.5124	168,978	3,473
Dynamic	0.5100	1,477,136	112,169
Dynamic + 原文兜底	0.3997	341,097	75,900

类别 5 单列：4 题，各策略按既有拒答规则匹配均为 4/4，不并入 F1。token 为各策略 20 题全部查询尝试的提供方用量，含失败、重试和各阶段，不含复用 Build 的构建。Full Text 输入完整对话，RAG 采用各自证据预算。

Dynamic 有 2 题实际触发结构化失败后的原文备用路径，结果按请求策略汇总，并保留实际执行策略；该组不是关闭备用路径的纯动态消融。

另完成 40 题证据检索检查：K 计初始 Memory 排名数，覆盖计映射后去重的 gold Source Turn，逐题算覆盖再平均。

K	初始 RRF	Dense 通道诊断	BM25 通道诊断
5	64.17%	62.92%	57.08%
10	72.92%	74.17%	63.33%
20	77.92%	79.17%	66.67%

结果分析：Hybrid F1 为 0.5124，Dynamic 为 0.5100；同组查询总 token 分别为 172,451 和 1,589,305，Dynamic 约为 Hybrid 的 9.2 倍。本轮未观察到 Dynamic 的整体优势，需要进一步核查状态变化问题上的收益和额外开销。原文兜底也未总体胜出。

当前真实 Build 尚无 SUPERSEDE / CONFLICT，两类真实关系质量未评；合成冲突仅验证处理流程。10 个动态案例作者审阅为 9 条正确、1 条部分支持，存储关系另有 2 处语义异议，未独立复核。单对话单轮展示不能代表跨对话或留出集表现。〔5〕 〔7〕

5 问题、后续安排与证据索引

5.1 两个需要处理的真实案例

QA51：枚举画作时遗漏 sunrise，部分分组超出明确文本。已确认答案覆盖不全；遗漏发生在抽取、召回、有效证据选择还是生成，尚待定位。下一步对照 gold 原文、初始 / 扩展 / 有效集合及答案，确定缺失阶段后修正，并用固定题复核。〔5〕

state-02：回答把“现有对话未报告完成收养”表达为“确定尚未完成”。已确认结论强于证据，具体引入阶段待查。下一步对照 Trace 定位越界处，校正证据不足与否定事实的表达边界，并加入有 / 无明确完成证据的成对检查。〔7〕

5.2 尚未完成的评价与下一步

未完成项	下一步与证据
留出集测试	尚未完成；冻结实现、题单和预算后，在 conv-43/44 测试并单列结果，不用留出成绩调参
跨对话评测	尚未完成；先在 conv-30/41/42 固定少量同类状态问题，按对话比较回答、证据覆盖与 token
独立动态质量评价	未独立复核；需取得独立核查的关系与有效证据判断，再评价状态变化子集；优先保留并核查现有异议

下一阶段先完成现有失败案例定位，再按固定范围逐步推进上述评价。中期报告呈现当前成果与初步结果。

5.3 依据与结果索引

〔1〕 M3 需求规格说明书 v0.3（2026-10-22，待团队复核）；Issue #4 实现规格历史副本供参考。

〔2〕 ADR 0001 架构、ADR 0002 最新评测范围。

〔3〕 原始数据、展示固定计划。

〔4〕 运行指南、构建与版本、有效证据问答。

〔5〕 展示分析与真实页面截图、逐题指标、最终审计。

〔6〕 合并前验证、早期 MiniLM 检查。

〔7〕 动态案例及已有异议、关系与有效证据记录。