Software Requirements Engineering · M5 Final

面向长期对话的动态记忆系统

设计、实现与评测

第三组「在阴雨天游泳」

莫远序
组长 · 核心系统与实验

黎志丽
Product Console

卓新烨
时间 / 事件 Sidecar

田亦洁
汇报材料与演示视频

github.com/kenqia/locomo-dynamic-memory · 2026 年 11 月 9 日

合成示例

长期对话里，难的是判断一句话 " 现在还算不算数 "

两句话都和问题高度相关，只有结合时间和关系，才能给出正确答案

对话里发生了什么

5 月 1 日 "I live in Paris."

5 月 2 日 "I moved from Paris to Rome."

相似度检索会同时找到这两句话

同一个问题，两种时间

"Alex 现在住在哪？ "

→ Rome

"Alex 5 月 1 日住在哪？ "

→ Paris

计划 ≠ 已完成

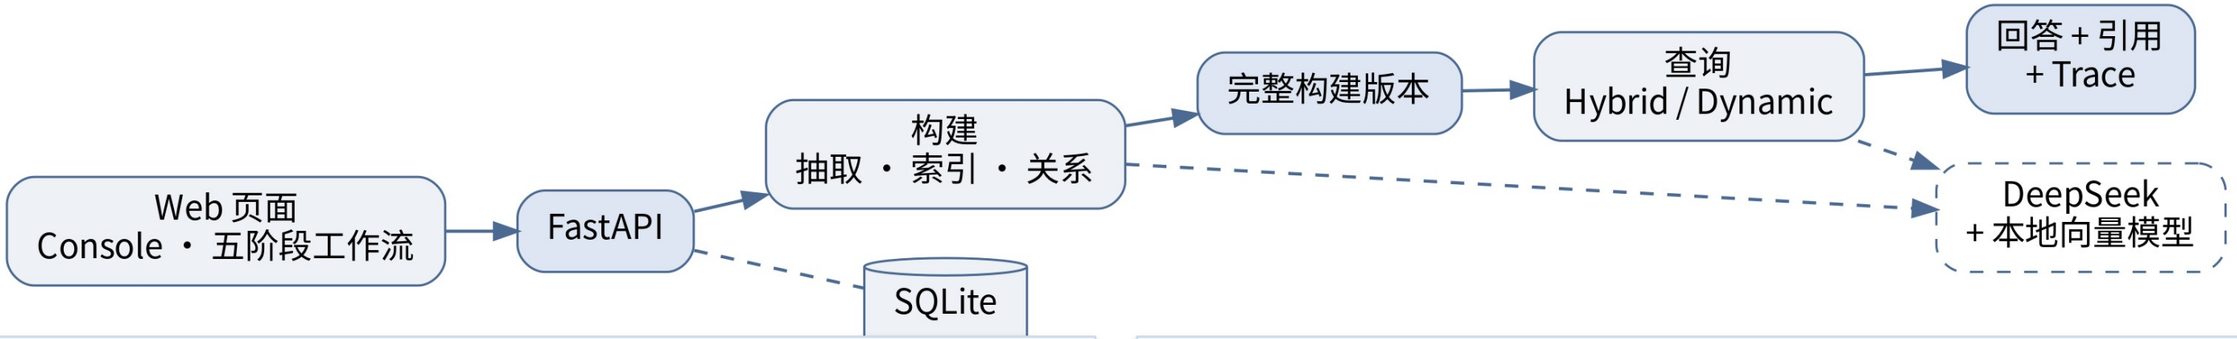
否定也要保留

矛盾不能擅自消解

我们想回答：查询时多一步 " 有效证据解析 "，能否稳定地提高回答质量？代价多大？证据在哪一步丢失？

五个阶段的需求，落在同一个可追溯的系统里

导入对话 > **构建记忆** > 检查记忆 > **问答** > 评测



技术选择

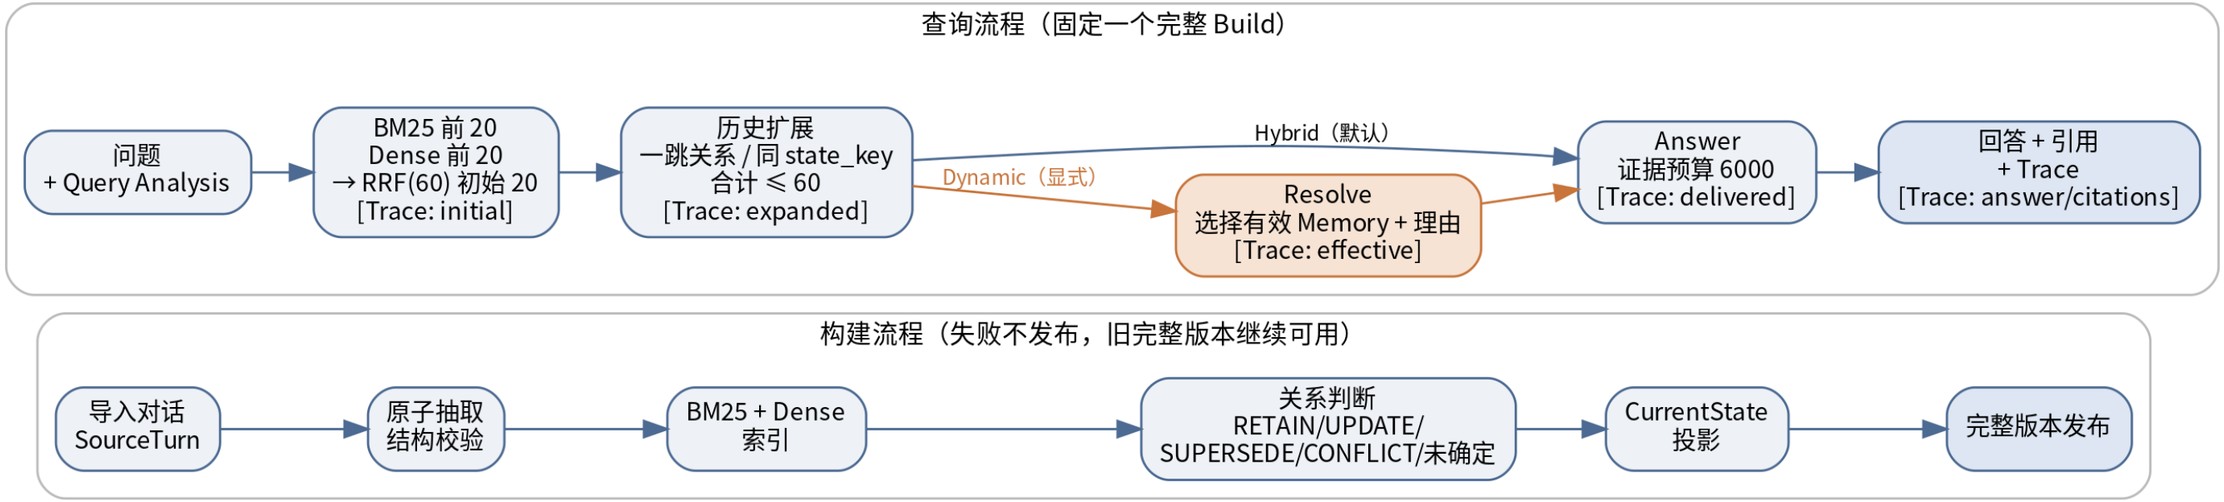
Streamlit 页面 → FastAPI → SQLite
BM25 + 本地向量模型（MiniLM，384 维）
DeepSeek deepseek-flash：抽取、关系、回答

三条质量要求

可追溯：任何回答都能定位到原文
版本一致：一次查询只用一个完整版本
失败可见：失败被记录，不当成 " 没有结果 "

Hybrid 与 Dynamic 共享检索和历史扩展，只差 " 解析 " 这一步

Dynamic 多调用一次模型，从候选中挑出对这个问题、这个时间有效的记忆

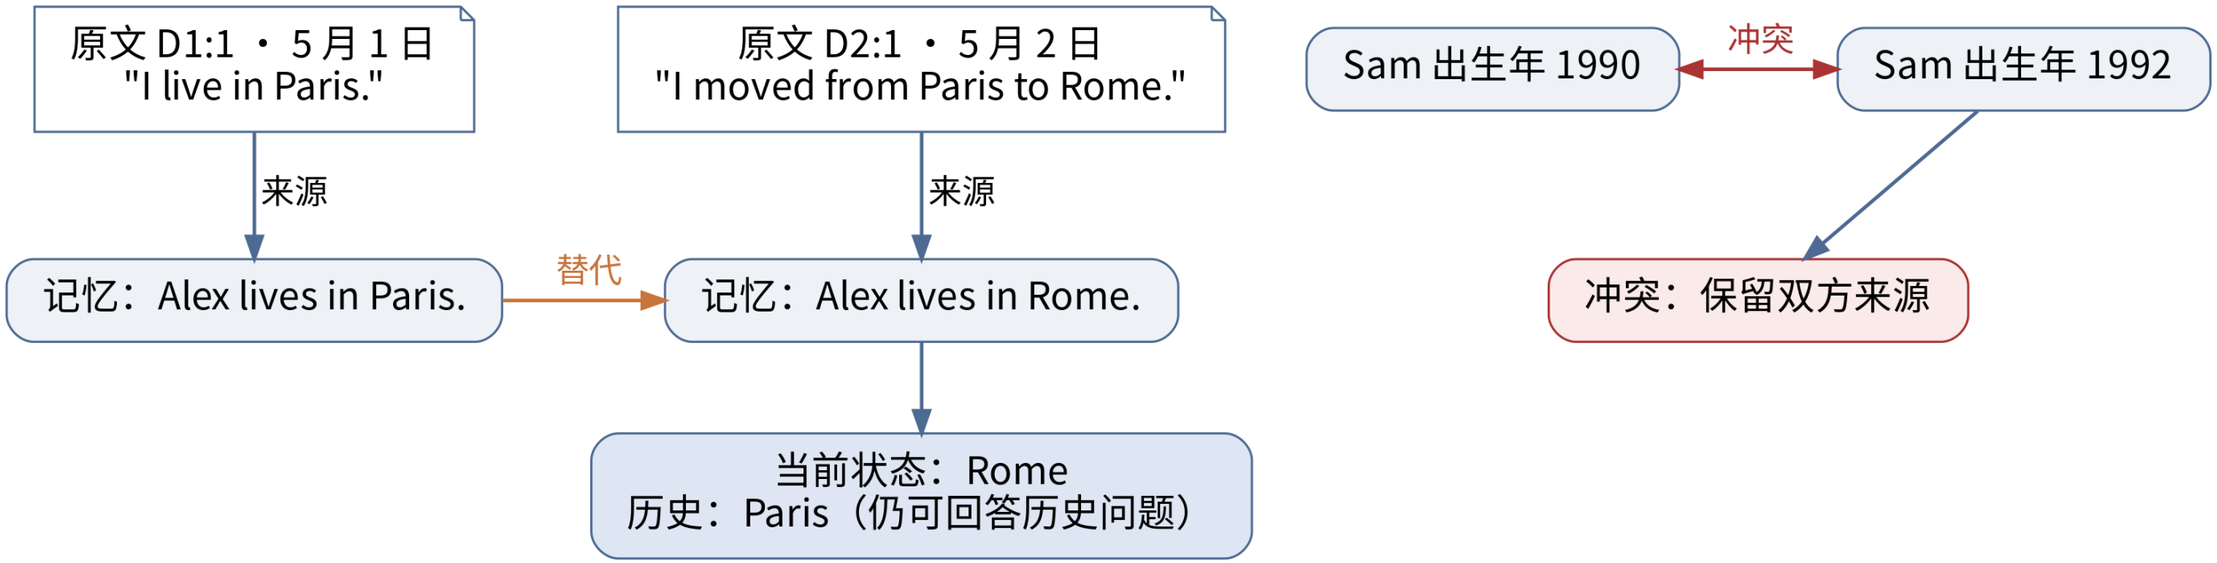


构建：按片段保存进度，失败只重试失败片段；任何一步没完成，版本就不发布，旧版本继续可用。

查询： BM25 与向量各取 20 → RRF 融合 → 历史扩展（⩽ 60 条）→ [解析] → 回答，并记录四阶段 Trace 。

合成示例

新信息不覆盖旧信息，每个回答都能回到原文



原子记忆

一条记忆 = 一个事实
指向原始轮次，记录计划 / 否定

记忆关系

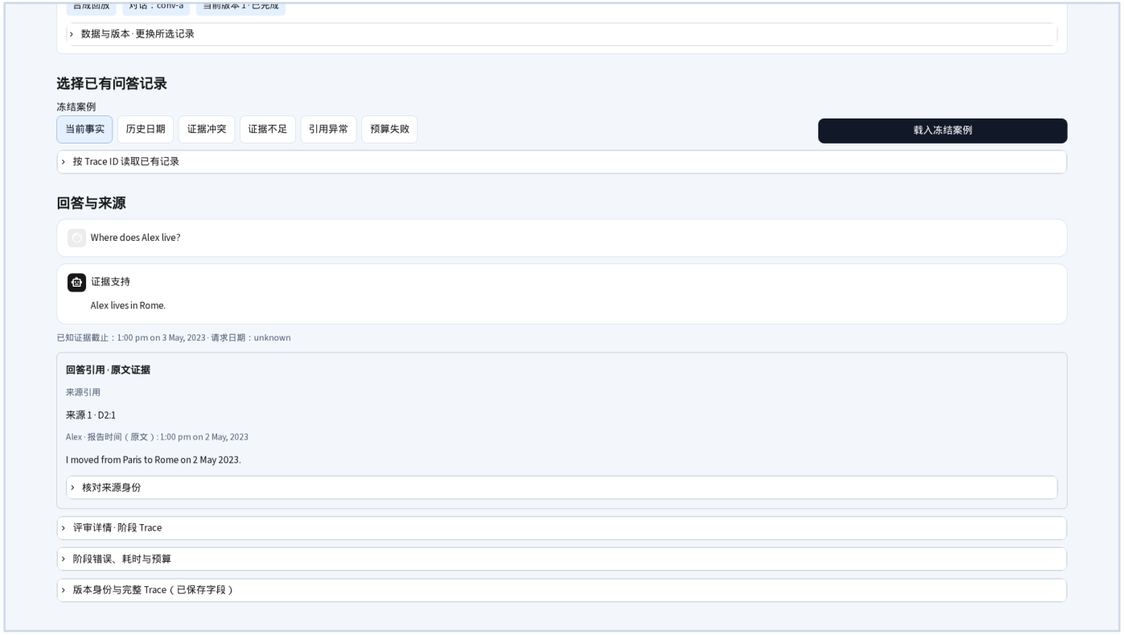
替代 · 推进 · 冲突 · 保留 · 未确定
当前状态可随时重算

两种时间

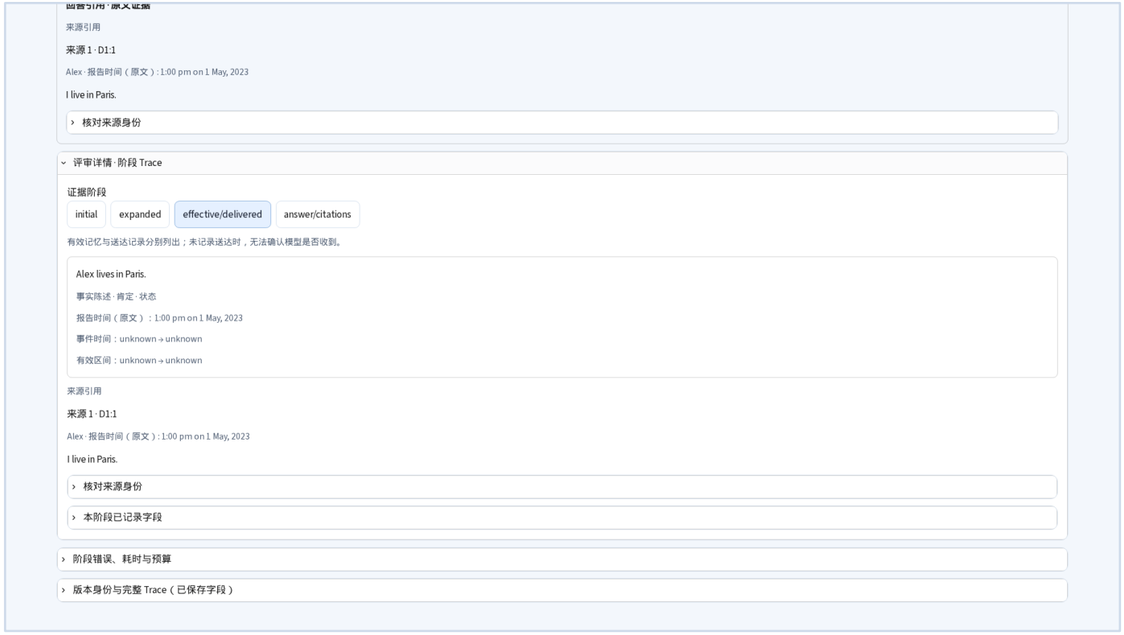
报告时间 ≠ 事件时间
" 现在 " = 最后一次会话

OFFLINE SYNTHETIC REPLAY

在 Console 里，可以从回答一路检查到原文和每个阶段的证据



当前事实： "Alex lives in Rome." ，引用 D2:1 原文



历史日期问题：切换到 " 有效证据 " 阶段的 Trace

五个页面： Overview · Memory · Query · Experiments · Demo ；只读浏览，不会自动构建或调用模型

工程质量： 主分支持续集成通过；离线测试 1,018 项全部通过；组员真人复核

最终结论来自一次事先固定配置的独立留出实验

400 题目

conv-43 / conv-44
开发期间从未看过成绩

2 策略

Hybrid 与 Dynamic
每道题各运行一次

0 分

失败题记 0 分
不补跑、不删除

三条原则

1 先固定配置，再看答案

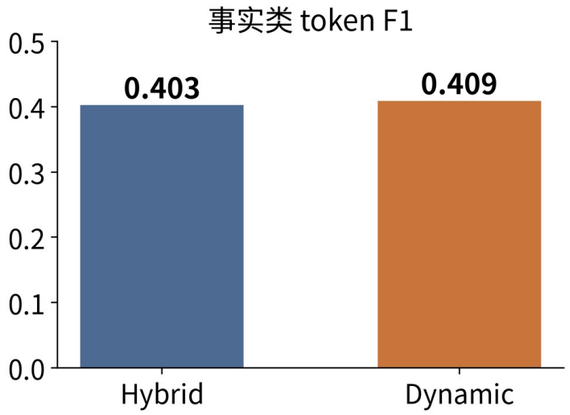
2 每道题只跑一次

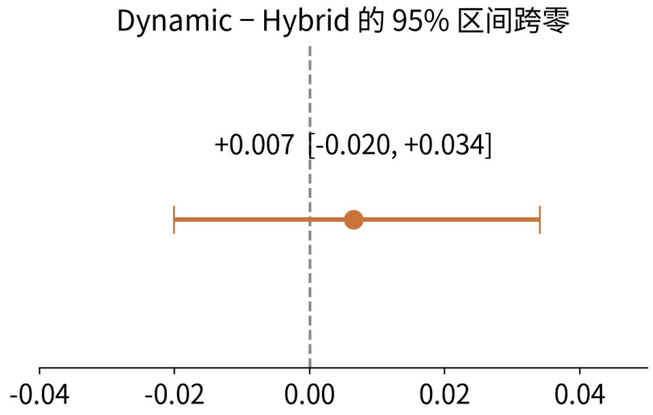
3 确认结果完整后才评分

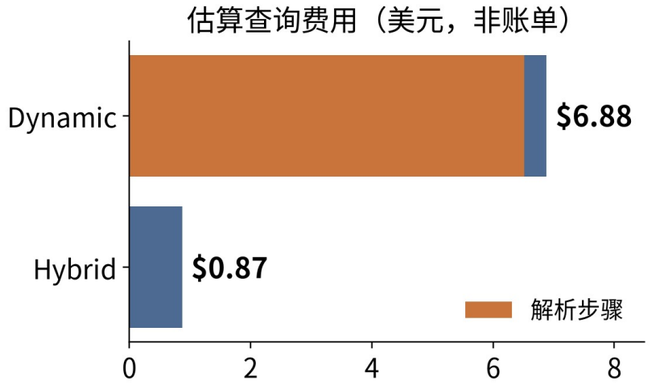
指标：事实类问题用官方 token F1；逐题配对 bootstrap 求 95% 区间；同时记录费用、延迟和失败。

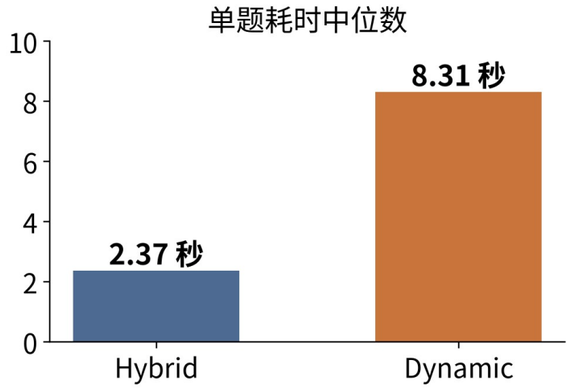
开发阶段： 757 题和 100 题的多轮实验用来发现问题、确定配置；样本与配置不同，不和最终结果比较。

Dynamic 的 F1 点估计略高但区间跨零；费用和延迟高出数倍









0.403 vs 0.409

事实类 token F1

差 +0.007 ， 95% 区间 [−0.020, +0.034]

7.90×

估算查询费用

按已报 token 用量估算，不是实际账单

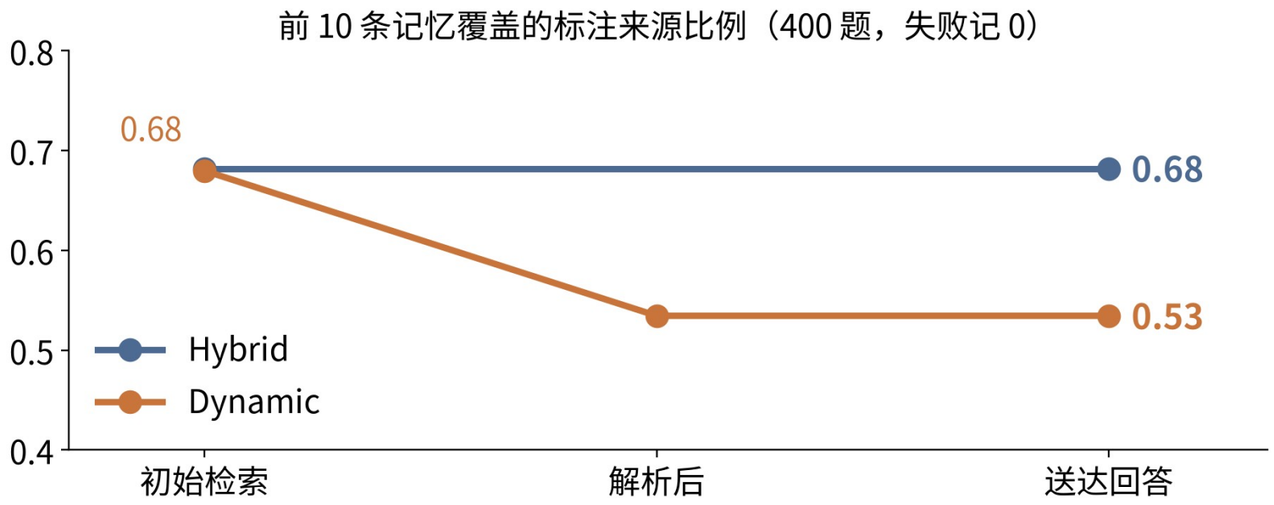
3.51×

单题中位延迟

2.37 秒 vs 8.31 秒

成功 394 vs 389 / 400； 17 次失败中 9 次为供应商余额不足

标注来源主要在解析步骤减少；扩展方向没有显示问答收益



107 / 400 题在解析后少了至少一个标注来源

2 / 400 题在回答阶段因篇幅限制再丢失

这不是 107 次错误删除：标注来源不一定是必需证据，例如问 Tim 、来源却在讲 John 。哪些排除是错的，还需要人工逐题判断。

已有探索与当前边界

Graph 两跳检索

最终证据覆盖不变

记忆压缩

节省可以忽略

自适应路由

证据覆盖下降

时间软优先

没有整体收益

时间 / 事件 Sidecar

已合入 main：默认关闭的离线诊断

默认 Hybrid ， Dynamic 显式可选

我们的结论

系统：从原文到记忆、关系、版本和带引用回答的完整链路，可以在网页中逐层检查

质量：区间跨零，没有证明 Dynamic 稳定更好

代价：估算费用约 7.9 倍，中位延迟约 3.5 倍

证据：减少集中在解析步骤，原因仍待判断

值得继续研究的方向

A · 双时间语义：区分事实发生时间与系统获知时间

B · 证据充足度检索：按缺失证据补检，而非盲目扩大 Top-K

C · 可证明关系 Graph：检验事件路径是否有来源支持

D · 更强 Benchmark：补充 LongMemEval 、 MemoryAgentBench 、 LOCOMO-CONV

一个看起来合理的设计，在独立数据上没有显示稳定收益，同时付出了明显成本。

我们把它如实记录下来，并据此做出工程选择。