面向长期对话的动态记忆系统

设计、实现与评测｜M5 五页课程报告

第三组「在阴雨天游泳」

Software Requirements Engineering · 2026 年 11 月 9 日

摘要

长期对话中的事实会随时间变化，也会出现计划、否定与相互矛盾的陈述。仅依赖语义相似度检索，容易把过时信息当成当前事实，且难以解释答案来自哪里。本项目实现了一个可追溯的动态记忆系统：将对话转为带时间和来源的原子记忆，记录记忆之间的保留、推进、替代与冲突关系，并在固定构建版本上检索和回答。系统提供 Web Console，可从回答、引用和检索 Trace 回到原始对话。

我们比较两种查询策略：Hybrid 使用 BM25 与向量混合检索后直接回答；Dynamic 在回答前增加一次有效证据解析。对两段开发期间未查看成绩的留出对话进行 400 题双策略实验。事实类问题 token F1 分别为 0.402606 和 0.409151，差值 +0.006545，95% 配对区间 [−0.020133, +0.034035] 跨零，未证明 Dynamic 有稳定质量优势；其估算查询费用约为 7.90 倍，中位延迟约为 3.51 倍。因此系统默认采用 Hybrid，Dynamic 保留为显式可选策略。

1. 项目问题与目标

长期记忆的核心问题不只是“找到相关内容”，而是判断信息在什么时间有效。例如，用户先说“我住在巴黎”，之后说“我搬到罗马”。询问当前住址应回答罗马；询问搬家前的住址则应回答巴黎。计划不等于已完成，否定也是需要保留的事实，互相矛盾的信息不能被系统擅自覆盖。

项目目标有三项：

- **可追溯：** 每条记忆和回答均可定位到原始对话轮次。
- **保留历史：** 新信息不覆盖旧信息，而是显式记录关系。
- **时间明确：** 区分陈述时间、事件时间与查询所采用的时间截止点。

系统围绕三个研究问题展开：RQ1，增加证据解析是否稳定提高回答质量；RQ2，其费用、延迟和失败情况如何；RQ3，正确证据在检索、扩展、解析和回答的哪个环节减少。

2. 主要成果

交付包括完整的记忆构建与问答系统、可检查记忆和引用的 Web Console、离线合成演示模式，以及冻结配置的对照实验和研究档案。项目并未只报告正向结果：Dynamic 的收益不确定、成本明显增加，这一负面结果直接影响了默认策略选择。

3. 系统设计与实现

3.1 架构与数据模型

系统采用前后端分离的单体架构。Streamlit Console 通过 FastAPI 访问业务功能；SQLite 保存原文、记忆、关系、构建版本和查询记录；BM25 与本地向量模型共同提供检索能力。抽取、关系判断和回答使用 DeepSeek API。离线演示读取合成快照，不连接研究数据库、不调用模型，也不需要 API 密钥。

核心对象包括：

- **Source Turn：** 原始对话轮次，是引用追溯的基础。
- **Memory：** 可独立核对的事实，带有主体、方面、陈述性质、否定标记、时间和来源。
- **MemoryRelation：** 表示 RETAIN、UPDATE、SUPERSEDE、CONFLICT 或不确定关系。
- **CurrentState：** 根据历史记忆和关系计算出的当前状态，不作为新的事实来源。
- **Build：** 将同一轮构建的原文、记忆、关系、状态与索引绑定为一致版本。

一次查询只使用一个完整 Build。查询时的判断写入 Trace，不修改全局关系和状态，从而避免查询顺序改变记忆库。

3.2 时间语义与处理流程

系统区分三种时间：陈述/会话时间（何时获知）、事件时间（事情何时发生）和查询的状态截止时间。未指定日期时，“现在”取所选对话最后一次会话时间。计划不会自动成为当前状态；被替代的旧记忆仍可回答历史问题。

构建流程为：导入对话 → 抽取并校验原子记忆 → 建立 BM25/向量索引 → 判断记忆关系 → 计算当前状态 → 发布完整 Build。任何阶段失败都不发布不完整版本。

查询流程为：问题分析 → BM25 与向量各取前 20 条 → RRF 融合 → 沿关系和人物历史有界扩展（最多 60 条）→ 生成回答。Hybrid 将候选直接交给回答模型；Dynamic 先增加 Resolve 步骤选择有效证据，再生成回答。两者的主要实验差异就是这一步解析。

3.3 证据追溯与 Console

回答包含答案、解释、证据状态和引用。引用指向记忆及原始轮次；Trace 记录初始候选、扩展候选、解析后证据、实际送达回答的证据和最终引用。引用位置真实不代表引用一定支持答案，因此实验另行审阅了回答与来源的语义对应关系。

Product Console 提供 Overview、Memory、Query、Experiments 和 Demo 页面，可检查记忆、时间、关系、来源、回答和 Trace。默认问答策略为 Hybrid；Dynamic 需显式选择。Graph 两跳、压缩、自适应路由等未进入默认路径。

4. 实验设计与结果

4.1 实验设计

使用 LoCoMo 的 10 段长对话。conv-26、30、41、42 用于开发；conv-43、44 在开发开始前选为本地留出集。最终对照 E25 使用 400 道题，两种策略各运行一次。所有配置在读取标准答案前固定；失败按 0 分计，不补跑、不删除。留出集仅两段对话，不能代表老师的隐藏评分集。

事实类问题（类别 1–4，每种策略 301 题）采用官方 token F1；对抗类问题（类别 5，99 题）单独报告拒答得分。逐题差异用配对 bootstrap 计算 95% 区间。费用按报告 token 用量及当时价格估算，不是实际账单。

4.2 主要结果

指标	Hybrid	Dynamic
事实类 token F1（301 题）	0.402606	0.409151
对抗类拒答得分（99 题）	0.858586	0.808081
成功完成（400 题）	394（98.50%）	389（97.25%）
估算查询费用	$0.87	$6.88
单题中位延迟	2.37 秒	8.31 秒

事实类 F1 差值为 +0.006545，95% 配对区间为 [−0.020133, +0.034035]，跨过零。逐题变化为 60 题提高、56 题降低、185 题不变。点估计虽偏向 Dynamic，但现有样本不足以证明稳定优势。

Dynamic 费用约为 Hybrid 的 7.90 倍，中位延迟约为 3.51 倍。解析步骤贡献了绝大部分额外输入成本。两策略分别成功 394 和 389 题；17 次失败中，8 次为模型输出格式错误，9 次为供应商账户余额错误（HTTP 402）。失败均保留并计入分数。

4.3 证据保留分析

标注来源覆盖的下降主要发生在 Dynamic 的解析步骤：逐题统计中，107 道题在解析后少了至少一个标注来源，只有 2 道题在回答阶段丢失来源。需要强调，107 并不等于 107 次错误删除；被排除的来源可能与问题无关。Tim/John 案例说明，来源存在不代表它是回答所需证据。当前仍需人工核查这些排除是否合理。

5. 工程质量、结论与后续工作

5.1 工程验证

Product 基准离线测试 1,018 项通过；Sidecar 合入后的独立专项测试 183 项通过。最新交付快照的完整本地公开回归为 **1,201 项通过、0 失败**；解包后 52 项专项测试、Chromium 六类场景均通过。配音演示视频为 291 秒、1920×1080、30 fps，H.264/AAC，全片解码通过，字幕 46 条。上述自动化结果不替代非作者对视频全片和提交文件的真人签收。

六段真实对话记忆导出共 2,031 条 Memory、37,445 条关系、1,465 个 Source Turn，通过 Schema、来源、时间与版本一致性检查。这证明导出结构完整，不代表每条关系在语义上都正确。完整 JSON 是受控实验材料，不随公开仓库或 Notion 分发。

5.2 结论与局限

项目完成了从对话导入、记忆构建、历史关系、版本管理到带引用回答和 Trace 的系统闭环。实验未证明 Dynamic 有稳定质量优势，却显示出明显成本和延迟；因此选择 Hybrid 为默认策略，Dynamic 显式可选。证据减少集中在解析阶段，但错误排除比例尚未确定。

局限包括：留出集只有两段对话；结果已经公开，后续只能用于回归；尚无人工标注的动态关系数据；来源审阅为 AI 辅助且并非人工金标准；费用是估算值；当前检索主要支持英文。

5.3 值得继续研究的方向

1. **双时间语义的动态记忆（优先）：** 区分事实发生时间与系统获知时间，检验不同 as-of 查询是否得到正确答案。现有 session_time、event_start、valid_from、valid_to 和 Source Turn 可作为基础。
2. **证据充足度驱动的自适应检索：** 在固定 Token 预算下，判断人物、时间、事件和关系证据是否充足，只沿有依据的关系补检，并与固定 Top-K 公平比较。
3. **基于可证明关系的 Graph Memory：** 表达带来源支持的事件参与者、顺序和因果路径；评价路径是否有证据、是否改善答案，而非边的数量。
4. **更有挑战性的 Benchmark：** 在 LoCoMo 之外补充 LongMemEval、MemoryAgentBench 和 LOCOMO-CONV，检验跨会话、时间、更新、遗忘及组合式对话查询。

6. 团队分工与复现

团队成员为莫远序、黎志丽、卓新烨、田亦洁。工作分别覆盖项目管理与核心系统/实验、Product Console、时间事件 Sidecar、Web 交互与演示材料。详细职责和过程记录见完整版报告与项目过程材料。

代码仓库：https://github.com/kenqia/locomo-dynamic-memory 。使用 Python 3.12 与 uv：`uv sync --locked --python 3.12`；运行离线演示：`uv run --locked python tools/team_v2/demo.py replay`，访问 `http://127.0.0.1:18501`。离线演示使用合成数据，不调用模型。LoCoMo 原始对话及真实 Memory JSON 不包含在公开提交包中。

参考文献

1. Maharana et al. (2024). *Evaluating Very Long-Term Conversational Memory of LLM Agents*. ACL.
2. Robertson & Zaragoza (2009). *The Probabilistic Relevance Framework: BM25 and Beyond*.
3. Cormack et al. (2009). *Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods*. SIGIR.
4. Xu et al. (2025). *A-Mem: Agentic Memory for LLM Agents*. NeurIPS.
5. Wu et al. (2025). *LongMemEval*. ICLR.
6. Hu et al. (2025). *MemoryAgentBench*. arXiv:2507.05257.
7. Chang & Chen (2026). *LOCOMO-CONV*. arXiv:2609.03467.

详细版本： `Final_Technical_Report_Full.pdf/.docx/.md`，并附 39 页 Research Supplement，供助教按需深入查阅。