LoCoMo 动态对话记忆系统：实验工程补充材料

2026-10-19 至 2026-11-05；2026-11-09 诊断更新

kenqia

2026-11-09

目录

摘要 **2**

1 引言 **3**
1.1 任务与研究问题 . . . 3
1.2 主要结论 . . . 3
1.3 范围与阅读说明 . . . 3

2 系统与评测口径 **4**
2.1 流水线 . . . 4
2.2 术语 . . . 5
2.3 指标 . . . 5
2.4 模型与配置 . . . 6

3 人与 AI 代理的分工 **6**

4 实验记录 **6**
4.1 阶段一：系统跑通与首轮真实实验（10-19 至 10-21） . . . 6
E0 系统构造与工程验证（10-19，背景） . . . 6
E1 首次完整构建与关系契约系列（10-20） . . . 7
E2 质量增量 A–E（10-20） . . . 8
E3 分阶段 thinking 与 10 题四策略，及答案输出修复（10-20 至 10-21） . . . 9
E4 证据覆盖优化、回滚与旧计划取消（10-21） . . . 9
E5 五策略现状展示（10-21） . . . 9
4.2 阶段二：机制归因与局部迭代（10-27 至 11-01） . . . 10
E6 五组动态机制消融（10-27 至 10-29） . . . 10
E7 回答诊断细化与 Top7 迭代（10-29） . . . 11
E8 原文分块替代结构化链路（10-29 至 10-30） . . . 11
E9 Top145 系列（10-29 至 10-30） . . . 11
E10 安全集成 RC1/RC2 与 Production v1（10-31 至 11-01） . . . 12
4.3 阶段三：全量基线与失败图谱（11-01 至 11-03） . . . 13
E11 三轮预算 smoke（11-01） . . . 13
E12 四对话全量基线（11-01 至 11-03） . . . 13
E13 失败图谱与 Hybrid/Dynamic 配对（11-03） . . . 14
E14 E1 路由、E5 缓存与 E6 可逆表示，均为离线（11-03） . . . 14
E15 Phase 5 canary 与 Phase 6（11-03） . . . 15
4.4 阶段四：证据损失定位与替代方向（11-03 至 11-04） . . . 15
E16 Phase 7 独立事实质量审阅与阶段归因（11-03） . . . 15
E17 Phase 7 D1 查询期原文锚点与 D2 邻接角色上下文（11-03） . . . 16
E18 Phase 8：Hybrid + Cross-Encoder 重排（11-04） . . . 17
E19 Phase 9：Hindsight 后端验证与 Qwen3 0.6B 本地抽取探针（11-04） . . . 17
E20 M5 Level A/B 模块回放、PropMem 探针与关系审阅（11-04） . . . 18
E21 40 题 query-specific 有效证据选择诊断（11-04） . . . 19
4.5 阶段五：冻结评测（11-04 至 11-05） . . . 19
E22 Level C v1：开发集固定 200 项真实实验（11-04） . . . 19

E23 Level C input v2（11-04） . . . 20
E24 留出集 conv-43/44 的构建与多轮恢复（11-04 至 11-05） . . . 20
E25 Level E 独立留出评测（11-05） . . . 21

5 跨实验综合 **23**
5.1 实验谱系 . . . 23
5.2 RQ1：答案质量 . . . 24
5.3 RQ2：可靠性与成本 . . . 26
5.4 RQ3：证据损失的位置 . . . 28
5.5 候选的最终去向 . . . 28

6 实验工程方法 **29**
6.1 完整失败分母 . . . 29
6.2 先冻结，后评分 . . . 29
6.3 每个付费阶段单独授权、单独记账 . . . 29
6.4 新配置就是新身份 . . . 29
6.5 不靠放宽校验来“修复” . . . 29
6.6 区分“已证明”与“仍未证明” . . . 30
6.7 复核身份分开标注 . . . 30
6.8 用 AI 编码代理推进实验 . . . 30

7 局限与有效性威胁 **30**

附录 A 实验总表 **30**

附录 B 失败类型目录 **32**

附录 C 成本表 **33**

附录 D 实验身份表 **34**

附录 E 实验门槛与规则清单 **35**

附录 F 未测量项 **36**
图表目录 . . . 36

附录 D：2026-11-09 证据损失诊断与边界回归 **37**
D.1 主要损失发生在哪一步 . . . 37
D.2 修复与验证边界 . . . 38
D.3 候选增加与最终交付 . . . 38
D.4 真实模型小回归：没有整体收益证据 . . . 38

摘要

本文记录我在 LoCoMo 长对话记忆任务上，从系统首次跑通到完成冻结留出评测这 18 天里的工程与实验探索。系统把原始对话抽取成带来源的原子 Memory；构建期判断 Memory 之间的状态关系（保留、推进、替代、冲突），查询期再按问题指定的人物、状态和时间选出有效证据。研究问题是：这套动态记忆机制（下称 Dynamic）能否在答案质量上稳定优于不做状态解析的混合检索基线（下称 Hybrid），代价又是多少。

全文按时间顺序记录 26 个实验单元（E0–E25）。每个单元可能合并了多轮真实调用，均说明动机、设置、结果、失败诊断，以及它引出的下一个实验。主要结果如下。

- 在两段预先固定、开发期间没有读取答案的留出对话（conv-43、conv-44，共 400 题）上，我只运行了一次冻结评测。类别 1–4 的完整分母 F1 为 Hybrid 0.4026、Dynamic 0.4092，配对差 +0.0065，95% 题目 bootstrap 区间为 [−0.020, +0.034]，跨零。800 项非作者 AI 来源盲审中，Dynamic 在 297 个可判定配对上原文支持改善 28 对、退化 18 对，区间同样跨零。
- 在同一批留出题上，Dynamic 的查询费用约为 Hybrid 的 7.9 倍（按已报 usage 和峰时单价折算），单题 p50 延迟约为 3.5 倍。

- 在开发集上，Dynamic 的表现首先取决于运行可靠性。输入预算不足时，Dynamic 有 49/100 项失败，完整分母 F1 比 Hybrid 低 0.17；放宽输入预算后全部成功，F1 高 0.044，但区间仍跨零。
- 失败归因显示，可以确认的语义损失主要发生在抽取阶段：8 个双审一致的错误拒答中，5 例是抽取遗漏。在留出集上，Dynamic 的有效证据解析使标注来源覆盖下降 0.08–0.19。

因此本文的主结论是一个零结果：现有证据不支持 “Dynamic 稳定优于 Hybrid”。我认为这份材料的价值主要在过程本身：每个实验怎样从上一个实验的失败中提出；结论怎样在完整失败分母、预先冻结、费用硬上限和非作者复核这些约束下得出；以及哪些候选最终被采用、保留为可选、搁置或淘汰。

1 引言

1.1 任务与研究问题

LoCoMo 的每段对话跨越几十个会话、几百轮交流。问题分为五类：多跳（类别 1）、时间（类别 2）、开放域（类别 3）、单跳（类别 4），以及答案不在对话中、应当拒答的对抗题（类别 5）。课程把 conv-26、conv-30、conv-41、conv-42 定为开发集，共 757 题。教师的最终评分集不公开。项目开始时，我把 conv-43、conv-44 预先定为本地留出集（共 400 题），规定在系统冻结前不查看这两段对话的模型成绩和标准答案。

长对话里的事实会变化：人搬家、换工作、计划取消。只按语义相似度检索，可能把过期的旧事实交给回答模型。Dynamic 的设想是：在构建期记录事实之间的演化关系，在查询期按问题所指的时间和状态挑出仍然适用的证据。本文围绕三个问题展开：

- **RQ1 质量**：在完整分母下（运行失败记零），Dynamic 的答案质量是否稳定优于 Hybrid?
- **RQ2 可靠性与成本**：Dynamic 多出的有效证据解析步骤，带来多少额外失败、费用和延迟?
- **RQ3 损失位置**：答案错误或遗漏时，证据是在抽取、检索、解析还是回答阶段丢失的?

1.2 主要结论

1. **RQ1**：在开发集固定 100 题和留出集 400 题上，都没有观察到区间不跨零的稳定增益。唯一一次区间不含零的结果是负向的（E22，−0.17），原因是输入限制导致的运行失败，而不是语义判断变差。
2. **RQ2**：Dynamic 的查询费用是 Hybrid 的 4.1 到 10.3 倍。可靠性曾是 Dynamic 的主要短板：在三个实验阶段中，它因完整解析输入超出预算而失败 5 到 49 项。放宽预算后，这类失败消失，成本随之上升。
3. **RQ3**：已确认的事实丢失主要来自抽取；Dynamic 的有效证据解析会删去部分标注来源，但被删来源是否真的不适用，没有独立测量。在开发数据的关系参考样本中，SUPERSEDE 和 CONFLICT 的出现次数为零，conv-44 构建出的 6,973 条关系中有 6,769 条是 “未确定”。Dynamic 针对的 “状态替代” 现象，在这批数据里可能本来就很少。
4. **过程**：大量候选改进在局部样本上有效，在同题对照或更大分母下消失。被保留下来的主要是工程约束：显式失败分母、来源绑定、输入预算保护和可恢复的构建。

1.3 范围与阅读说明

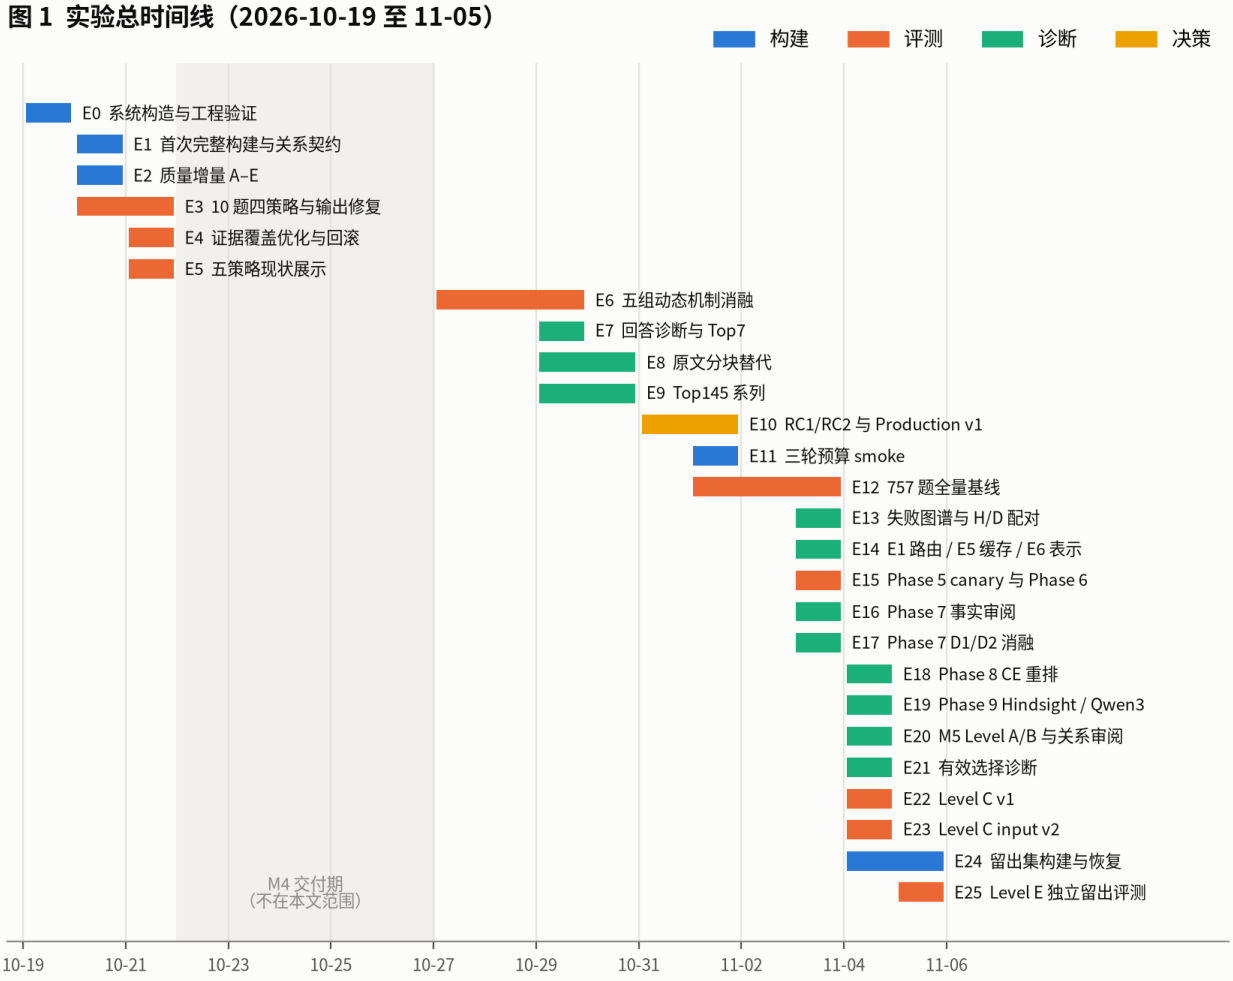
本文覆盖 2026-10-19 系统首次跑通到 2026-11-05 留出评测结束。课程 M1–M4 的报告与交付材料、11 月的展示冲刺不在范围内；10-19 的系统构造（E0）只作为背景简写。

全文的数字口径如下：

- **H / D**：分别指 Hybrid（`hybrid_no_resolution`）和 Dynamic。
- **完整分母**：运行失败、超时和预算拒绝都留在分母里并记零；unknown 项给出上下界。“仅成功项” 的分数会单独标出，只作参考，因为它按运行结果筛选，带有选择偏差。

- **已曝光开发题**：开发集上的结果都来自已经被反复诊断过的对话，不能当作泛化证据。只有 E25 是在留出集上的一次性评测。
- **语义审阅**：除特别说明外，答案与来源的语义判断都由未参与该实验实现的 AI 审阅者完成，不是人工或教师真值。
- **费用**：分三种口径。“预约” 是发送前按最坏情况扣减的额度；“已报峰价” 是按 provider 返回的 usage 和官方峰时 cache-miss 单价折算的金额；实际账户账单我没有读取。三者不能互换。
- **跨实验比较**：不同实验的样本、Prompt 版本和 thinking 设置不同，表格里的分数不能跨实验直接相减。

图 1 实验总时间线（2026-10-19 至 11-05）



2 系统与评测口径

2.1 流水线

图 2 系统流水线与各阶段的主要失败点（红色虚线框）

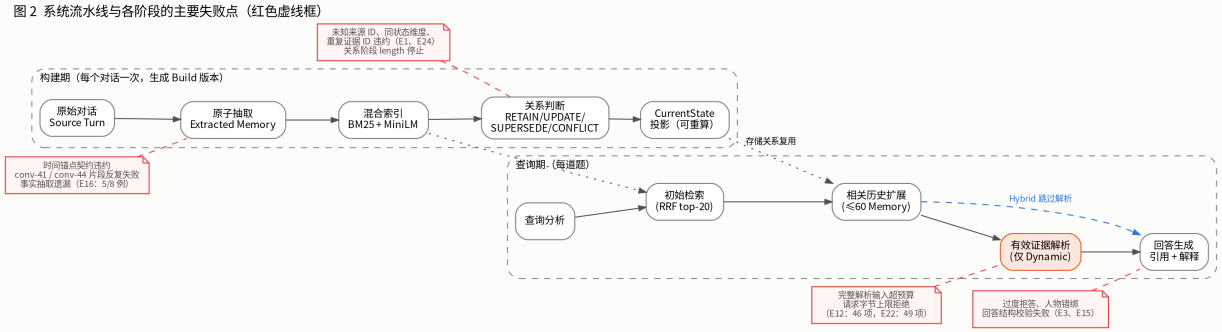


图 2 是系统的完整流水线。构建期对每段对话运行一次，产出一个 Build 版本：

1. **原子抽取**：把原始对话按片段送入模型，抽取出一条条原子事实（Memory）。每条 Memory 带内容、陈述性质（事实、计划或不确定）、时间表达及其原文锚点，以及一个或多个来源轮次（Source Turn）。校验器拒绝没有来源、引用不存在的轮次、或时间表达不在锚点原文中的输出。
2. **混合索引**：BM25 加固定版本的 MiniLM 本地向量，用 RRF 融合。
3. **关系判断**：对同一人物、同一状态维度（state_key）的 Memory 对，由模型判断 RETAIN（继续适用）、UPDATE（同一过程的阶段推进）、SUPERSEDE（新值替代旧值）、CONFLICT（无法消解的矛盾），或“未确定”。每条关系都要求有逐字原文证据。
4. **CurrentState 投影**：根据历史 Memory 和已确认关系重算的当前状态摘要。它是可重算的投影，不是另一份事实来源。

查询期对每道题运行：

1. **查询分析**：识别问题涉及的人物、状态和时间。
2. **初始检索**：取 RRF 排序前 20 条 Memory。
3. **相关历史扩展**：沿存储的关系和同状态维度补充历史 Memory，最多 60 条。
4. **有效证据解析**（只有 Dynamic 执行）：模型阅读扩展后的完整候选，判断哪些 Memory 在本题所指的时间和状态下仍然有效，必要时补判构建期没有确定的关系。这一步需要把全部候选一次送入模型，所以输入很长，是后文多次“完整解析输入超预算”失败的来源。
5. **回答生成**：回答模型基于交付的证据作答，必须给出引用和解释；证据不足时应拒答。

Hybrid 在第 3 步之后直接进入回答。早期实验还比较过 Full Text（把完整对话直接送给回答模型）、Vector（只用向量检索）和原文兜底（`dynamic_raw_fallback`，Dynamic 证据不足时再检索原文窗口）。

2.2 术语

术语	含义
Source Turn	原始对话中可定位的一轮，由对话 ID 和轮次 ID 共同确定
Memory	从原始对话抽取、带内容、时间和来源的原子事实
MemoryRelation	有来源证据支持的 Memory 之间的关系：RETAIN、UPDATE、SUPERSEDE、CONFLICT 或未确定
CurrentState	由历史 Memory 和已确认关系重算的当前状态，可以包含未消解的冲突
有效记忆	在问题所指的时间与状态下可以用于回答的 Memory，不一定是最新的一条
Build	一次构建对应的来源、Memory、关系、投影和索引的共同版本；配置是 Build 身份的一部分
Run	一次评测运行，固定题单、策略、Prompt 和配置，结果逐项持久化
证据损失	原始对话支持的应答事实在抽取、选择、交付或回答阶段丢失

2.3 指标

指标	定义	主要局限
官方类别 F1	类别 1–4 使用上游规则的 token F1	字面重合，不等于事实正确
类别 5 字面拒答	回答是否按规则字面拒答	不是事实正确率，单独报告

指标	定义	主要局限
完整分母 F1	全部计划项的均值，失败记零	混合了可靠性与质量
来源 Recall 代理	前 K 条 Memory 关联的唯一 Source Turn 对标注来源的覆盖	来源命中不代表事实被抽对
来源盲审	非作者 AI 通读原文后，逐项判断原文支持、引用支持、拒答是否合理，以及人物、事件、时间错误和列表遗漏	每项通常只有一名审阅者，不是人工真值
配对差与区间	同题 D–H，按题 bootstrap（固定 seed）得到 95% 区间	只描述所选对话内的题目不确定性

2.4 模型与配置

全部真实调用使用 DeepSeek 官方接口的 `deepseek-flash` 别名，temperature 0，JSON 输出。实验期间官方价格页把该别名映射为 DeepSeek-V4.1-Flash-1017，但响应只返回可变别名，所以我无法证明服务端权重在整个实验期间没有变化。早期 Build 中关系判断使用 high thinking、有效证据解析使用 low，其余阶段关闭 thinking；M5 冻结评测（E23–E25）的所有新生成操作都关闭 thinking，历史 Build 的配置原样保留。Embedding 使用固定 revision 的 MiniLM，在 CPU 上运行。

3 人与 AI 代理的分工

这是一份个人视角的材料，需要先说明 “我做了什么”。我作为研究者负责：提出每一轮的研究问题，确定实验协议和比较条件，批准每个付费阶段的调用次数和金额上限，决定何时停止、回滚、恢复或采用。实现代码、执行实验、整理结果和初步审阅，由 AI 编码代理在我的授权下完成。各轮的设计讨论先以访谈形式进行，确认后才写成 ADR、spec 或实验协议，再进入实现。

语义复核按身份分开记录：作者代理的自查、未参与实现的非作者 AI 审阅、格式与哈希核验，各自单独标注。E6 中有两批答案（6 份与 4 份）由同组成员 B 按盲审方式提交，按原记录收到的提交如实标注，本文没有另行核实其身份或过程。本文没有把 AI 完成的实现或运行写成我亲手完成的实验，也没有把任何 AI 审阅称为人工真值。

4 实验记录

每个实验单元按同一结构记录：**动机**（上一步暴露了什么）→ **设置** → **结果** → **失败与诊断** → **决定与下一步**。为节省篇幅，简单单元把若干项合并成一段。

4.1 阶段一：系统跑通与首轮真实实验（10-19 至 10-21）

E0 系统构造与工程验证（10-19，背景）

10-19 这一天完成了系统的首个可运行版本：导入、抽取、检索、关系、问答、版本恢复，以及浏览器端验收。这一阶段只验证工程契约，模型调用全部是受控夹具，不产生任何质量结论。

模块	验证内容	结果
导入与来源隔离	10 段对话、5,882 轮只读检查；评测标注与原文隔离	11 项通过；未知会话、SQL 列数和时间戳元数据问题先失败后修复

模块	验证内容	结果
原子抽取	空白 Memory、非法结构、来源校验、片段级提交与重启恢复	27 项通过、1 项跳过
混合检索	BM25 + 固定 MiniLM + RRF；超长输入拒绝	39 项通过、3 项跳过，另 2 项真实本地编码检查通过
关系与发布	非法来源、未来或条件状态、部分发布被拒绝	62 项通过、3 项跳过
当前与历史问答	计划、冲突与证据不足的区分；英文日期解析	69 项通过、3 项跳过；日期解析先失败后修复
恢复、导出与并发	子进程中断、发布竞态、索引身份	各阶段失败都保留，不覆盖已成功部分
浏览器与 CI	Playwright 端到端、故障注入	112 项通过、4 项跳过；早期独立审查发现的安全问题已修复

这一阶段确立了后续实验都遵守的三条工程约束：失败必须显式保存，不能静默重试；未完成的 Build 不能被查询；评测运行逐项持久化，中断后显式恢复，unknown 不自动重发。

E1 首次完整构建与关系契约系列（10-20）

动机：用冻结的原始契约对 conv-26 做第一次真实完整构建。

首次构建：21 个片段抽取在一次显式恢复后得到 295 条 Memory。关系阶段计划 292 个任务，结果是 89 成功、29 失败、1 中断、173 待执行。保存下来的 provider 调用有 220 次，其中一部分 usage 缺失，按未知处理。原始 29 个失败任务共 87 次尝试，其中的具体错误子类没有保存，事后无法统一推断根因。

子实验：我没有直接重跑整个 Build，而是固定原始候选和输入顺序，做了一系列小规模独立回放，每轮都单独批准调用上限：

子实验	调用	改动	观察
同状态维度前提对照	6（前后各 3）	把校验器对 RETAIN/CONFLICT 已有的 “同 state_key” 要求写进 Prompt（relations-v2）	单候选任务 relation:2 由失败转为通过；两个 20 候选批次仍失败，其中一个从 “同维度违约” 变成 “联合规则违约”
重复证据 ID 修复	4（前后各 2）	先把联合错误码拆成 “空白理由” 和 “重复证据 ID” 两个，定位到后者；Prompt 增加去重指令（relations-v3）	relation:44、relation:90 两个批次都转为通过，覆盖 20/20；但全部 40 个判断都是 “未确定”
v3/v4/v5 固定任务复验	9（每版 3）	v4 补充旧事实与新非事实的标签前提；v5 让校验器与 Prompt 共用同一个标签可用性函数，把每条旧 Memory 允许的标签直接放进输入	v3、v4 在 relation:112 上仍报 `factual_resolution_required`；v5 三项全部通过

子实验	调用	改动	观察
v5 完整构建	累计 313	用 v5 新建独立 Build	抽取和索引完成；关系阶段先后出现输出长度截断、逐字引用违约，最后在 HTTP 错误处停止。Build 置为 interrupted，不发布、不跑 QA
v6 / v6.1 / v6.2 语义关卡	25	在长输入和语义对照案例上设置五道关卡	24 次结构成功，1 次 HTTP 402；第五道关卡（案例 172）始终失败，因此阻止完整重建。早期把对照案例 148 判为 “接受” 的结论后来被撤回

诊断：两类问题交织在一起。一类是**契约可见性**：校验器执行的规则没有完整写进模型可见的指令里，模型无从遵守。这类问题通过补充指令或共享规则函数逐个修复。另一类是**语义正确性**：结构合法、引用逐字匹配，不代表关系判断正确。案例 172 把 “完成项目” 和 “描述同一件作品” 判成阶段推进（UPDATE），结构完全合规，语义却是错的。

决定：第一类修复全部保留；第二类不靠追加 Prompt 或硬编码 ID 来 “修”。完整重建被语义关卡挡住，后续实验改为先在小范围定位，再决定是否扩大。

E2 质量增量 A–E（10-20）

动机：E1 的语义关卡没有通过。我提出四项 P0 和一项 P1 改进，经访谈确认后分成五个相互独立的增量，每个增量都有自己的调用上限（每个不超过 16 次）。

增量	内容	真实请求	结果
A 抽取示例	为抽取 Prompt 增加计划与事实、人物指代、事件阶段、否定句的正反对照	4	四个合成语句的结果另交非作者核对；不代表总体质量
B 关系候选	优先比较同一人物、同一状态维度；修复同键旧事实被近期 24 条计划挤出	2	73/91 两个案例的回放符合预期；没有验证案例 172
C 阶段证据契约	UPDATE 必须给出合法的阶段推进证据	3	73 判为有阶段证据的 UPDATE、148 判为 RETAIN；**172 仍判为 UPDATE**，并同时给出两个 true 谓词
D 有界原文兜底	新策略：证据不足时最多做一次 BM25 原文窗口检索和一次联合解析	7	先后暴露两个契约歧义（模型把 Memory 来源放进原文 ID、联合解析选中已被拒绝的 Memory），补充说明后探针通过
E 证据精简	`focused` 模式按词面裁剪候选，保留完整同键与关系连通组	6 + 4	输入从 4 条减到 3 条；v2 只在单人物、单问题时裁剪，3 条减到 2 条。非作者复核发现 v2 的两份答案都漏写了截止日期

结果：合计 26 次真实请求。局部契约和输入量有所改善，但没有通过整体语义验收：案例 172 仍误判 UPDATE，focused 输出存在边界遗漏。完整离线回归第一次跑出 311 通过、13 失败；修复共享校验后再跑完整回归，324 项通过。

决定：A–E 的工程实现保留，默认仍使用 `expanded` 证据模式。没有冻结新的完整身份，C 的真实尝试就此停止，不再继续堆 Prompt。

E3 分阶段 thinking 与 10 题四策略，及答案输出修复（10-20 至 10-21）

动机：给不同阶段设定不同的 thinking 强度，并放宽关系输出上限，看能否得到第一个完整可查询的 Build。

设置：v1、v2 两个 Build 失败后，v3 完整构建成功。在 v3 上固定 10 道题，运行四种策略，共 40 项。

结果：

运行	成功 / 计划	Dynamic	原文兜底	Hybrid	Full Text
初轮	24/40	9/10	4/10	3/10	8/10
输出修复后同题复验	40/40	8 题 F1 0.334	8 题 F1 0.340	—	—

初轮有 16 项因答案结构校验失败。修复回答契约和输出提示后，同一 Build、同一题单重跑，40 项全部成功（共 98 次请求）。在 8 道可比题上，Dynamic 的 F1 从 0.154 升到 0.334，原文兜底从 0.039 升到 0.340。

诊断：初轮的成功数主要反映的是回答输出能否通过结构校验，而不是答案质量。复验一次改了多处，无法分离每项改动的贡献。初轮也没有 “全部关闭 thinking” 的对照组，不能把差异归因于 thinking 强度。

决定：保留修复后的回答契约。初轮不支持 “原文兜底总体更优” 的说法，这一点在 E5 中做了专门检验。

E4 证据覆盖优化、回滚与旧计划取消（10-21）

动机：E3 复验中仍能看到关键证据没有交付给回答模型。我尝试用重排和 “列表类问题枚举补查” 提高证据覆盖。

设置：固定目标题和未见题，共 30 项 A/B，不重建 Memory。另做了查询可靠性、来源日期、列表多样性的定向修复，以及 citation 跟进回放，各自保存为独立快照。

结果：30 项全部运行成功，但没有看到稳定提升。QA3 的完整关键证据组仍然超出预算；QA15 的补查反而挤掉了原本的支持证据。在新问题组上，原文兜底的 F1 低于 Hybrid。

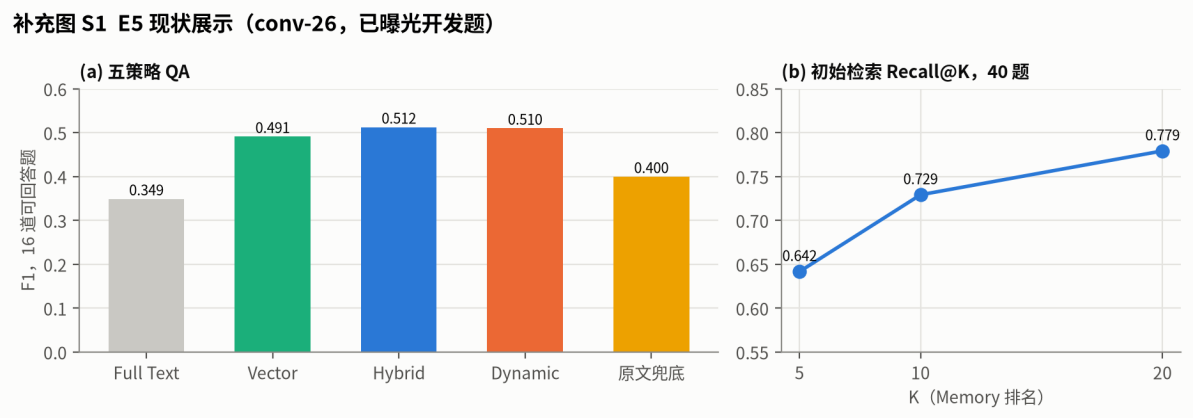
决定：按我的决定回滚 P0/P1 的三个提交，保留 P2 的工程修复；原始失败记录不覆盖。同一天我停止扩展原定的 757 题 × 4 策略、共 3,028 项全量计划，转为小步增量迭代。这一计划在 E12 中以新的身份重新执行。

E5 五策略现状展示（10-21）

动机：回滚之后，用一组固定样本如实展示系统现状，并直接检验 “原文兜底总体更优” 这一假设。

设置：复用 conv-26 已有的完整 Build，不重新抽取、不重跑关系。题单在生成前冻结：用固定种子从每个官方类别各取 4 题，共 20 题，五种策略共 100 项。同轮另有三项检查：40 题初始检索 Recall，10 个真实动态关系场景（4 个 UPDATE、3 个 RETAIN、3 个未确定），以及对 20 条 Dynamic 和原文兜底回答的来源审阅。本轮新增 307 次调用（批准上限 420 次）。

结果：100 项全部运行成功。16 道可回答题的 F1：Full Text 0.349、Vector 0.491、Hybrid 0.512、Dynamic 0.510、原文兜底 0.400。初始检索 Recall@5/10/20 为 0.642 / 0.729 / 0.779。



诊断：Dynamic 有 2 道题实际走了备用路径。来源审阅由当时的开发助手完成，属于作者自查。当前 Build 里没有真实的 SUPERSEDE 或 CONFLICT 关系，所以这组样本无法评估这两类关系的质量。审阅还对两条已存储关系的语义提出了异议。

决定：否定 “原文兜底总体更优”。Hybrid 与 Dynamic 的差距只有 0.002，在 16 道题上无法区分。下一步需要回答：Dynamic 的各个机制分别贡献了什么。

4.2 阶段二：机制归因与局部迭代（10-27 至 11-01）

E6 五组动态机制消融（10-27 至 10-29）

动机：E5 显示 Dynamic 和 Hybrid 在小样本上几乎打平。要回答 RQ1，先要知道 Dynamic 的每个机制分别贡献了什么。我通过访谈确定了一份消融协议（ADR-0003），只把可以归因到查询期的贡献作为主张。

设置：在 conv-30、conv-41、conv-42 上各自隔离构建，固定同一对话的 Memory、索引和初始候选。五组 A–E 分别打开或关闭历史扩展、独立有效证据解析和存储关系复用，每组运行 3 次，计划最多 1,080 项。conv-26 留作已知问题的诊断，conv-43/44 留到冻结之后。协议规定：正式运行开始后，任何对题单、策略或 Prompt 的改动都会改变比较身份，必须另存，不能覆盖。

结果：正式的 1,080 项没有完成。

- **关系输出上限 16K**：第 107 次调用的结果用量未知，按协议停止。
- **关系输出上限 32K**（新的 campaign）：经过多次 transport 恢复，conv-30 构建完整；conv-41 抽取 33/34 片段，失败片段反复失败。
- **时间锚点因子探针**：四组有限对照最多 12 次请求，得到 8 份可用输出、4 份不可用，48 项事实判断待审；之后的反馈探针 3 次仍然失败，没有启动完整重建。
- **conv-30 四题 A/D 对照**：8 项中 6 项成功，2 项 D 组解析失败，共 14 次请求、392,178 tokens。成员 B 的盲审给出 3 个 accept、3 个 “需修改”，其中 2 项解释判断受限于审阅包缺少来源。D 组有两例把候选从 16 条压到 2 条，但这不等于降低了总成本。
- **解析契约修复与六题效果实验**：修复用了 4 次请求、214,263 tokens；随后的效果实验 4 成功、1 失败、7 未尝试，用了 10 次请求、129,252 tokens；成员 B 对其中 4 份答案的盲审为 A 组 1 accept、1 需修改，D 组 2 accept。第二个对话没有运行；失败项 mini03-A 的具体违约原因未知。

诊断：机制归因的前提是所有组都完整跑完。实际卡在了更上游的地方：conv-41 一个片段的时间锚点契约，和有效证据解析输出的结构契约。两份完整答案对不足以证明任何总体增益。

决定：停止五组消融，不从唯一完整的 conv-30 外推全部机制的收益。焦点转到一个更具体的问题：契约失败的根因能否被观测和定位。

E7 回答诊断细化与 Top7 迭代（10-29）

动机：E6 的历史失败只留下了通用异常信息，无法辨别根因。

诊断码细化：接受条件保持不变，只把通用异常换成固定的诊断码，并用 960 组合成输入验证：58 组接受、902 组拒绝，接受结果的变化为 0。这一改动提高了可观测性，但不能事后追认历史失败（如 mini03-A）的原因。

Top7 迭代：我列出七个稳定的问题条目（TOP7-001 到 007），顺序固定，逐项做离线修复，再用有限的真实调用检验：

- **离线修复**：内容包括时间锚点错误分类与定向反馈、请求前输入预算检查、回答来源须证明具体事件关联、冲突证据被截断时阻止只发送一方，以及完整的交接与分母登记。完整离线回归 527 项通过；后续分层契约版本为 630 项通过。
- **真实关卡**：六项诊断中 4 项技术通过、2 项失败（9 次 HTTP、81,966 tokens）。4 份输出经冻结后揭盲的 AI 语义复核：1 通过、2 失败、1 不确定。
- **证据目录开放探索**：48 次 HTTP。短证据地址带来局部的技术改善，语义增益不足。
- **thinking 成本与原文阅读**：103 次请求结算 448,646 tokens，第 104 次请求结果未知。同一组 8 题上，resolution 使用 low thinking 时完成且语义通过 8/8；改为 direct 是 2/8，完全关闭是 3/8。
- **reader v2**：从回答输入中移除抽取用的时间地址句柄，48 次 HTTP、99,193 tokens，全部终结。已知题上，原顺序的完成率从 v1 的 4/8 升到 v2 的 8/8，完成且语义通过从 2/8 升到 6/8；QA51 的语义仍然失败。

决定：保留显式 reader v2 和分层契约，均为可选项（opt-in）；关闭 thinking 来降本的方案被淘汰。七个父项都没有达到整体验收。

E8 原文分块替代结构化链路（10-29 至 10-30）

动机：抽取阶段反复出错。一个自然的问题是：能不能干脆不抽取，直接检索原文分块?

设置：10 个案例 × 3 组主比较 × 2 次重复，另加 8 项 reader 诊断和 12 项抽取，共计划 80 项，实际发出 78 次 HTTP。另有 2 项问答因上游失败没有发送，仍保留在计划分母里。三组为：结构化 Memory 链路、固定原文分块、完整全文。

组	技术交付	整体正确	干净的必需事实
结构化 Memory	18/20	11/20	64/78
原文分块	20/20	12/20	48/78
完整全文	20/20	16/20	70/78

诊断：原文分块的技术交付率更高，但必需事实少了 16 个，问题出在检索阶段没有把它们取回来。分块 reader 在已交付输入上的错误拒答为 0，但这只说明 reader 本身不是瓶颈，不能掩盖端到端的检索缺口。完整全文的事实最多，但也有遗漏和过度推断，而且成本更高。

决定：拒绝用固定原文分块替换默认的结构化链路。近似去重等方案没有实施，所以不把它们写成失败。

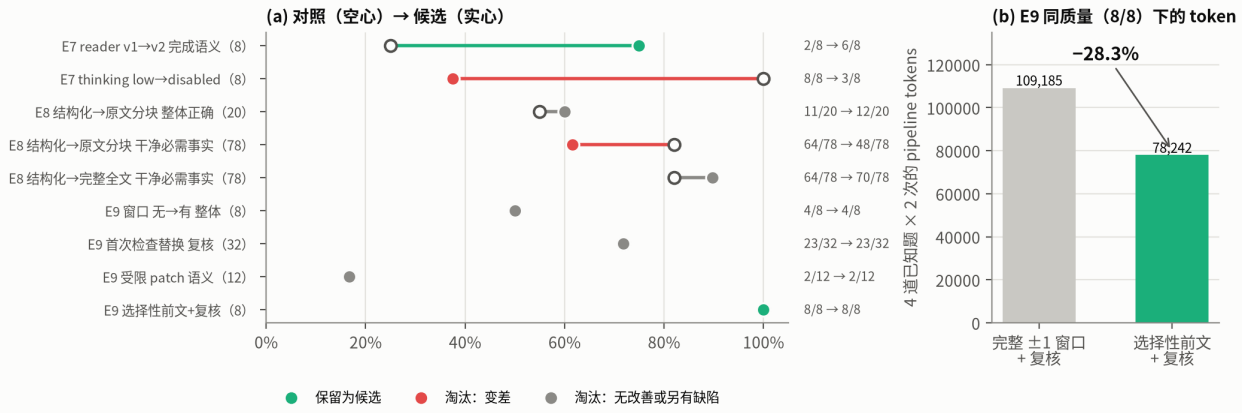
E9 Top145 系列（10-29 至 10-30）

动机：E7 的 Top 1、4、5 三项仍未解决，涉及单命题抽取、模态（计划或事实）、补充前文窗口，以及二阶段复核。

设置与结果：分四批，每批单独冻结：

批次	请求 / tokens	关键对照	结论
单命题、模态、notes、窗口	96 HTTP / 276,723	加窗口前后：技术 6/8 对 6/8，整体 4/8 对 4/8	单命题保留为局部可选项；notes、思考、窗口的整体替换都不成立
复核、时间索引、新边界	249 HTTP / 593,616	窗口 + 复核在已知题上 8/8，但需 108,925 tokens；12 个新边界上复核前后 19/24 对 19/24	保留窄范围候选；逐断言检查、独立盘点、源内时间索引淘汰
更便宜的首次检查	86 HTTP / 212,852	首次检查替换后总计 23/32 对 23/32，token 反而多 11.2%；conv-41 新增整批拒绝	淘汰首次检查替换；异语境抽取示例不默认采纳
受限 patch 与选择性前文	56 HTTP / 242,531	选择性前文 + 复核与完整 ±1 窗口 + 复核都是 8/8，token 从 109,185 降到 78,242（−28.3%）；patch 技术 6/12 对 4/12，语义 2/12 对 2/12	选择性前文作为局部降本候选；patch 不能当作完整修复

图 13 E7–E9 迭代：候选与对照的同题比较



样本均为已曝光开发题，单位各不相同（题、事实、输出）；只在同一行内比较。

诊断：多数候选在已知题上能修好原来的失败，换到新边界或同题对照就不再成立。唯一稳定的收益是在质量不变（8/8）的前提下降低了 token，样本只有 4 道已知题，每题跑 2 次。到这一轮结束时，维护系列累计已开始的 HTTP 请求为 696 次。

决定：七个父项仍未整体验收。保留下来的窄改动进入下一步的安全集成。

E10 安全集成 RC1/RC2 与 Production v1（10-31 至 11-01）

动机：把前几轮验证过的窄改动集成进稳定的默认路径，其余候选明确标记去向。

设置：先审查 26 项集成候选，RC1 和 RC2 分开保存。后续实验 INT-FOLLOWUP 使用 28 道题：12 道已曝光开发题、12 道合成题、4 道旧回归题。每题 2 次重复 × 3 组，每条 pipeline 先作答、再做一次通用复核，共 168 条 pipeline、334 次 HTTP。

结果：

- **已曝光开发题 24 个输出**：原版 17/24，复核后仍是 17/24；两种 guided 方案都是 24/24。

- **合成题 24 个输出**：原版 20/24，wide-guided 23/24，selective 22/24；复核前后都没有变化。
- **旧回归题 8 个输出**：三组复核前后分别为 6/8→7/8、6/8→8/8、7/8→7/8。
- **selective 的节省**：总 token 节省 15.76%，低于预设的 20% 门槛。
- **F01 四包表示**：可逆，但估算输入为 32,859–59,291，全部超过 24K 预算，因此一次真实解析请求都没有发出。

决定：Production v1 最终整理出 31 项规范化采用项，默认路径合入诊断码、来源预算、受限反馈和完整输入保护，并移除了“普通 Dynamic 失败后隐式用原文重跑”的行为，因为这个行为会让失败在分数里不可见。F01 不移植，F02 留作研究候选，F03 因未达门槛不采用。离线验收为 608 项测试通过、1,788 个契约组合。

4.3 阶段三：全量基线与失败图谱（11-01 至 11-03）

E11 三轮预算 smoke（11-01）

动机：E10 得到了 Production v1。在付费跑全量之前，先用固定的 5 题 × 4 策略（20 项）检查默认预算能否跑通 conv-26。三轮共用一个累计上限：¥40、500 次物理 HTTP、并发 1；每轮都新建身份，不拼接前一轮的结果。

轮次	改动	Build	QA	本轮 HTTP / 峰价
① 默认	输出上限 8,192	21/21 片段、273 Memory；关系 269 任务中 48 成功、3 失败、218 被阻塞，未发布	20 项执行前阻塞，没有 Run	84 / ¥3.21
② 输出 ×4	输出上限 32,768，新建 Build	275 Memory、269/269 关系，complete	15/20：Full Text、Vector、Hybrid 各 5/5，Dynamic 0/5，全部因解析输入超过 24,000 预算	322 / ¥17.58
③ 解析输入 ×4	解析输入预算 96,000，复用 ② 的 Build	不变	20/20 执行与结构验收通过	40 / ¥0.67

第 ② 轮有 32 次输出超过了旧的 8,192 上限，最大一次 20,201 tokens；所有请求都是正常结束（`stop`），没有截断。三轮累计 446/500 次 HTTP，峰价 ¥21.46。

诊断：默认配置的问题不在模型能力，而在两个预算参数。关系判断的输出天然很长；有效证据解析的完整输入经常超过 24K。E12 和 E22–E23 会反复回到这个问题（图 14）。

决定：全量基线使用研究参数，即输出 32,768、解析输入 96,000，生产默认不变。第 ③ 轮只证明研究参数下服务可用，不代表语义验收。

E12 四对话全量基线（11-01 至 11-03）

动机：在完整分母上取得 757 题 × 4 策略的真实基线，也就是 10-21 取消的那个计划，现在用新的身份重新执行。

设置：4 个开发对话，757 题 × 4 策略，共 3,028 项，输出 32,768、解析输入 96,000。Build 构建过程中先后发生 OOM、HTTP 402 和超时，每段恢复都单独保存，不拼接。

结果：3,028 项中 2,969 成功、56 失败、3 unknown。四策略完整分母 F1：Full Text 0.464869、Vector 0.519714、Hybrid 0.521886（含 1 个 unknown，上界 0.523207）、Dynamic 0.515133。Dynamic 709/757 成功，48 项失败中有 46 项是完整解析输入超过预算。

补充与修复：另建两个 Run，只针对原来失败和 unknown 的项。补充 Run 把解析输入提高到 192,000，59 项中 51 成功、8 失败；回答修复 Run 8/8 成功。两者都不回填原 3,028 项的分母。补充结果中仍有官方 scorer 给满分、AI 交叉审阅却指出引用失败（Citation Failure）的答案。

决定：原基线保持原样。Dynamic 在成功子集上的均值较高，不能用来掩盖 48 项失败。

E13 失败图谱与 Hybrid/Dynamic 配对（11-03）

动机：E12 的总分接近，我需要知道两边各自在哪些题上赢。

失败图谱：对三个 Run 分别建立 Failure Atlas，得到 2,053 / 41 / 8 条候选记录。候选记录不等于错误数。84 项匿名 AI 初审加 18 项交叉审阅后，8 项错误拒答被两边共同指出；明确的交叉 Citation Failure 只有 1 项，其余根因多为 unknown。

配对：

指标	值
配对状态	两侧都成功 705；仅 Hybrid 成功 48；仅 Dynamic 成功 3；unknown 1
705 对上 D 相对 H	136 胜 / 110 负 / 459 平，平均差 +0.026
胜题平均增益 / 负题平均损失	+0.305 / −0.210
完整分母 F1	Dynamic 0.515；Hybrid 在 [0.522, 0.523]
查询费用（峰时估算）	Dynamic ¥98.93；Hybrid ¥9.60，约 10.3 倍

诊断：两边都成功时 Dynamic 略好；把它独有的 48 项失败计入后，略差。增益集中在少数题上，单题幅度大；损失分布更广。

决定：现有结果不支持把更贵的 Dynamic 设为默认。下一步沿两条线走：降低 Dynamic 的成本，以及减少它的输入失败。

E14 E1 路由、E5 缓存与 E6 可逆表示，均为离线（11-03）

这里的 E1、E5、E6 是研究阶段内部的候选编号，与本文的实验编号无关。

- **E1 便宜路径路由**：目标是在能证明充分的题上走 Hybrid，只在需要时走 Dynamic。按对话做四折留一，规则不读取 gold、答案或后续分数。结果 757/757 题全部被路由到 Dynamic，便宜路径覆盖为 0，节省为 0。这是一个负结果，我没有在事后放宽门槛。
- **E5 查询编码缓存**：在切片测试中，冷启动编码 CPU 降低 64.2%，本地检索 CPU 降低 57.4%。移植到应用层后（19 题 × 3 次，模型用 Mock），冷启动 CPU 只降 7.9%，热启动的 wall time 反而增加 12.2%，没有达到 15% 的应用 CPU 门槛。provider 费用节省为 0。
- **E6-A 可逆关系表示**：完整解析输入不删证据，只换一种可逆的列式编码。757 题本地估算输入从 39,660,331 降到 26,051,688（−34.3%）。原来 46 项超限全部回到预算内，没有新增超限；129 条已有引文零丢失。这只是离线结果，真实 QA 和 provider 成本都没有评估。
- **Phase 5 执行器准备**：冻结 25 对 Control（192,000）与 E6-A（96,000）的配对输入，严格 Mock 演练 50 个 arm 全部成功，真实模型调用 0 次。

决定：E1 不进入付费筛选；E5 保留为可选项；E6-A 进入 E15 的真实 canary。

E15 Phase 5 canary 与 Phase 6（11-03）

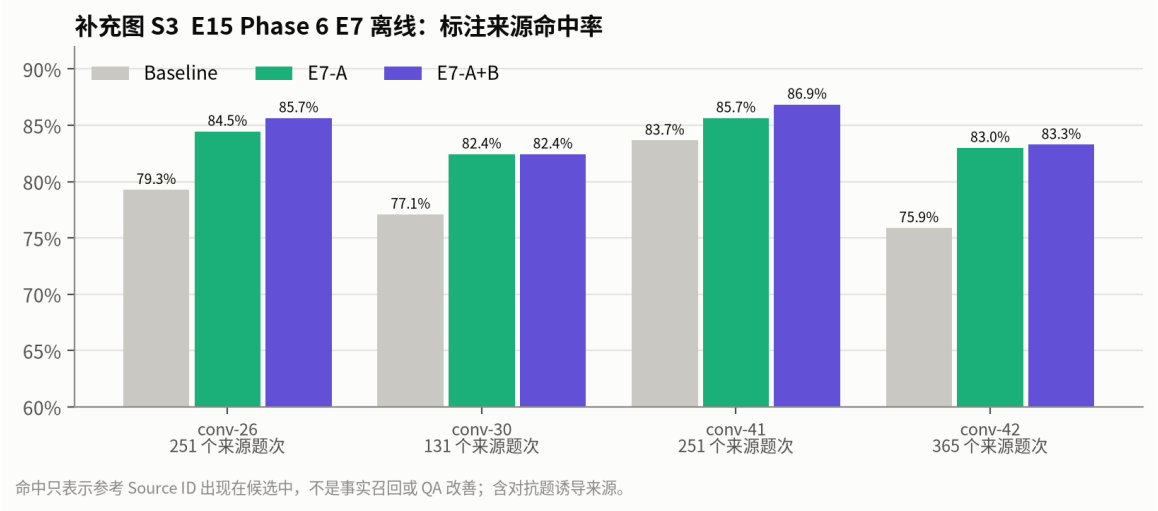
动机：E6-A 在离线上大幅缩短了输入，需要用真实调用确认它不损害语义。

Phase 5 canary：我单独授权了一次 ¥25 硬上限、8 次生成 HTTP、并发 1、不自动重试的 canary：2 道题 × Control/E6-A 两组。首次尝试因账户余额门槛设得过高而停止，原现场保留；第二次在新的授权下执行。

两题合计	Control	E6-A	变化
技术完成	2/2	2/2	—
prompt tokens	131,918	97,544	−26.1%
completion tokens	10,778	13,368	+24.0%
峰时费用	¥0.340	¥0.287	−15.3%
请求耗时合计	46.7 s	57.7 s	+23.5%

Phase 6 根因与复核：两名非作者 AI 独立复核了 4 份答案，结论一致：负对照题 conv-26 的核心遗漏和绘画参与者的错误归属是两组共有的问题，不是 E6-A 新引入的。逐阶段追溯显示，D17:25/26 的核心事实在抽取响应里就已经丢失；D8 的绘画问题是共指信息被弱化，回答所需的上下文没有交付，解析阶段把人错绑了，回答阶段沿用了这个错误。E6-A 在解析阶段曾选中另一个人（Gina）的证据，最终回答正确拒答，但这个人物判定风险必须保留。

E7 离线来源恢复：E7-A 让冻结开发集的候选标注来源命中增加 51/998 个题次，E7-A+B 联合增加 58 个；剔除对抗题后，非对抗题命中从 643 升到 677、再到 683（分母 820）。这只是来源重合，不是事实召回。



决定：E6-A 定为 `hold_for_semantic_risk`，不执行剩余 23 对。E7 默认关闭，不进入付费联合实验。根因指向抽取，下一步做一次覆盖面更大的事实审阅。

4.4 阶段四：证据损失定位与替代方向（11-03 至 11-04）

E16 Phase 7 独立事实质量审阅与阶段归因（11-03）

动机：E15 的两道题都把问题指向抽取。需要一个更大的、事先固定的样本来确认这一点。

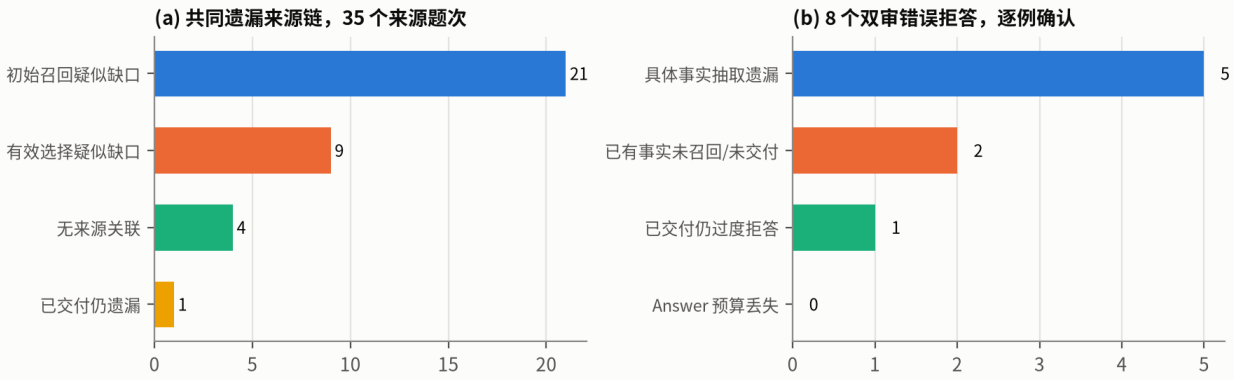
设置：用固定哈希在每个实际存在的 “对话 × 类别” 层中最多取 4 题，再全局补足到 80 题。先剔除 Phase 6 已知的 82 道诊断题，不按成绩筛选。对 Hybrid 和 Dynamic 的 160 份答案，两位非作者 AI 各自分页通读四段完整原文后独立审阅，隐藏方法标签、标准答案和分数。两份审阅先封存并记录 SHA，再揭盲。冻结后发现 160 份答案全部运行成功，因此这个样本不能用来估计运行可靠性。

结果：两位审阅者的事实切分粒度不同，不能混池计算一致性。两人都明确判定为错误拒答的，Dynamic 8/80、Hybrid 11/80。49 份存在严重错误或核心遗漏分歧的答案由主审回源复查，追加了 190 段逐字证据；复查后撤回或弱化了 4 项过强的判断，原审阅不变。

阶段归因：普通 80 题的共同遗漏来源链显示，21 次是初始召回疑似缺口，9 次是有效选择疑似缺口，4 次无来源关联，1 次已交付仍遗漏。单位是来源题次，这 35 次不是 35 个独立事实。另一名非作者审阅者针对 8 个双审一致的错误拒答，逐条检查了 978 条相关 Memory 和实际 Trace：

局部确认	案例数	说明
具体事实抽取遗漏	5	晚餐菜品与事件、昵称、明确的写作动机等；来源轮次关联着 Memory，但 Memory 里没有问题需要的内容
已有事实未召回、未交付	2	Memory 中有这条事实，后续没有送达回答模型
已交付仍过度拒答	1	纹身时间已交付但措辞模糊，问题并不要求精确日期
Answer 预算导致丢失	0	只限这 8 例

图 10 E16 证据损失的阶段归因



(a) 的单位是来源题次，不是独立事实；(b) 中部分案例存在阶段重叠，不能排他归因。

决定：部分案例同时存在召回和选择上的损失，不能排他归因。总体上哪一个阶段造成的语义错误最多，仍是未知。但在能确认的案例里，抽取遗漏最多。下一步尝试在不重建 Build 的前提下，从查询期补回原文。

E17 Phase 7 D1 查询期原文锚点与 D2 邻接角色上下文（11-03）

动机：E16 确认了抽取遗漏。重新抽取需要新的 Build 身份和付费构建；这里先试一个查询期的补救办法。

D2 邻接角色上下文：先检查在候选旁边补充有限的邻接对话轮次。双审发现新增的原文大量只是上下文、弱相关，或者不足以回答问题，D2 没有通过价值筛选。

D1 查询期原文锚点：查询时构造一个临时的 “原文风险目录”，不创建新 Memory，也不写旧 Build。没有关联任何 Memory 的轮次，以及有至少 3 个内容词没有出现在关联 Memory 里的轮次，被标为风险锚点；“3 个词” 是固定的工程启发式，没有搜索阈值。当解析结果不足，或问题内容词没有出现在已交付的原文中时，复用已有的 BM25 原文检索，最多取 2 个中心、4 轮、700 个估算 tokens。

离线消融：757 题保留完整分母，其中 711 题到达回答选择阶段，46 题因上游失败跳过。

指标	D1 only
触发题数	666
新增来源题次	1,566
新增标注来源命中	106
双审遗漏来源恢复	3/35
新增输入 token 代理	191,142

在 8 例双审错误拒答中，D1 只完整恢复了 1 例，部分恢复 2 例。

决定：D1、D2 都定为 HOLD，默认关闭，没有生成新答案，也没有接入生产。这个实验和 E15 中的 E7 是两件不同的事：E7 在候选阶段补充来源，D1 在回答前补充原文锚点。

E18 Phase 8：Hybrid + Cross-Encoder 重排（11-04）

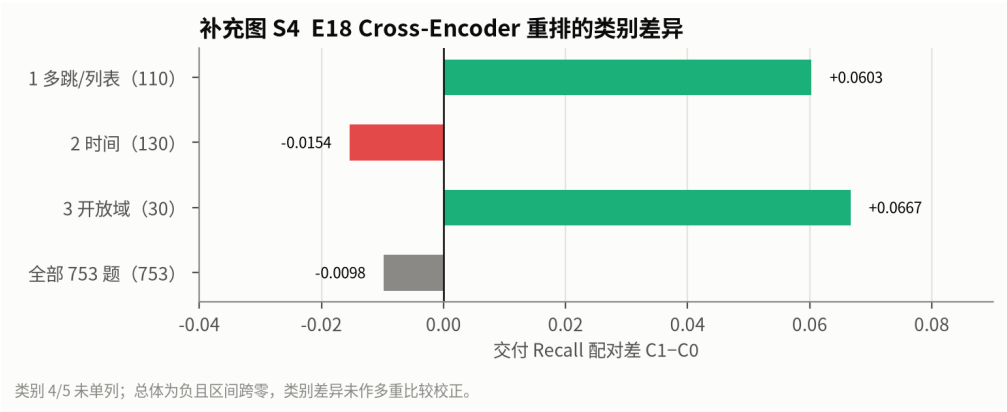
动机：既然抽取侧的补救收益很低，就换到检索侧，看更强的重排能否把已有的事实更多地交付给回答模型。

设置：在原 Run 的 757 题上本地回放，只改变一个变量：在 Hybrid 的初始排序后加一个 Cross-Encoder 重排（C1），与冻结的 Hybrid（C0）对比。所有检索输入只用原问题和原 Memory 索引文本；gold 和标注来源只在排序完成后用于统计。新增付费请求为 0。C0 在 757/757 题上与原候选、扩展和最终交付完全一致，说明回放本身是可信的。

结果（753 题可评分，来源覆盖代理）：

阶段	C0	C1	差值	改善 / 退化 / 不变
两路并集池	0.819387	0.819387	0	0 / 0 / 753
初始 20 条	0.782566	0.776442	−0.006	34 / 29 / 690
扩展后	0.819588	0.799004	−0.021	20 / 32 / 701
交付回答	0.773801	0.764011	−0.010	37 / 33 / 683

交付差的 95% 区间为 [−0.028, +0.008]（10,000 次 bootstrap）。四个对话的交付均值差全部为负。按类别看，多跳/列表类 +0.060、开放域类 +0.067、时间类 −0.015。从中抽 24 道题做独立 AI 审查：候选更好 2 题、对照更好 1 题、持平 20 题、不确定 1 题。



决定：未达到预设门槛，定为 HOLD。没有新的回答 F1。

E19 Phase 9：Hindsight 后端验证与 Qwen3 0.6B 本地抽取探针（11-04）

动机：检查一个外部的完整长期记忆后端（Hindsight），是否能直接替代本系统的抽取与存储。

合成验证：固定官方 commit（MIT 许可证），在只开回环网络的独立 namespace 中运行真实 API、PostgreSQL、异步 Retain/Recall 和后台 worker，抽取由官方测试 stub 驱动。数据完全是合成的：4 个会话，11 项预设事实，覆盖人物、同人不同事件、不同人同名事件、计划取消、新旧就业、相对时间，以及跨轮的 “we”。

契约	结果
异步构建	4 个 receipt 全部完成，无失败
事实 → chunk → 原文	11/11 可追溯，文本与 SHA 保持
7 个目标查询	7/7 召回目标事实，日期保持
历史与状态更新	新旧工作、计划与取消都保留，没有物理覆盖
逐事实轮次绑定	**不支持**：原生 chunk 中两个说话者的事实共享一个 chunk

小模型探针：在独立的本地 Ollama 上，用 Qwen3 0.6B 量化模型做了一次合成抽取（输入 2,663 tokens，生成 9 条 Memory）。逐条对照原文审阅发现：昵称方向颠倒、共同参与者遗漏、取消的计划遗漏、第二次比赛的 silver 名次和学习收获遗漏。时间错误中混有导出器的缺陷：跨会话输入没有内嵌各轮时间，不能归因于 Hindsight 本身。这一审阅属于作者自查。

决定：Hindsight 的真实数据 canary 和采用都定为 HOLD；“把原生 chunk 成员关系直接等同于逐事实来源支持”REJECT；“Qwen3 0.6B + 当前导出器” 这一具体配置 REJECT。这些结论不等于淘汰 Hindsight 的所有配置。

E20 M5 Level A/B 模块回放、PropMem 探针与关系审阅（11-04）

动机：在最终评测之前，系统检查剩下的几个附加模块，决定哪些进入真实实验。我把评测分为五级：A 为离线测试，B 为冻结输入回放，C 为开发集固定样本真实实验，D 为单模块真实实验，E 为一次性留出评测。

Level B 交付回放：757 题 × 6 组，全部复用生产的扩展与回答打包逻辑，不执行解析、Embedding 或 provider 调用。753 题可映射来源，4 题不可评分。

组	扩展后覆盖	交付覆盖	相对 D
H 冻结 Hybrid 输入	0.819588	0.773801	0
D 冻结 Dynamic 输入	0.819920	0.773801	0
B1 D + 两跳 Graph	0.823098	0.773801	0
B2 D + 可逆 wire 分组	0.819920	0.773801	0
B3 D + 自适应排序	0.820916	0.744452	−0.029
B4 D + 时间优先	0.819920	0.773801	0

- **B1 Graph**：在 444 题上确实找到了新的两跳路径，扩展候选新增 7,689 个 Memory 题次，但交付覆盖没有任何增益。
- **B3 自适应排序**：5 题改善、25 题退化、723 题不变，区间 [−0.043, −0.017]，四个对话全部为负。
- **B2 压缩**：完整回答消息从 5,558,932 个代理 token 降到 5,557,306，只减少 0.029%；757 题中只有 30 题启用。

PropMem 探针：固定官方 commit（Apache-2.0），对其上游方法做隔离的源码与合成检查，发现四个问题：联合问题只选中一个人、名称子串误配（Joanna 匹配到 Ann）、在没有真实矛盾时按新旧时间给旧事实降权、逐事实来源受限。直接采用其配置被 REJECT；没有运行真实抽取 canary，也不外推到整个方法家族。

关系审阅：两名独立 AI 分别审阅不重叠的 30 + 30 个关系单位，双方端点引文逐字核对通过。参考先冻结，之后才读取历史预测：50/60 正确，Accuracy 0.833，Macro-F1 0.767。参考标签中 RETAIN 33、UPDATE 4、未确定 23，**SUPERSEDE 和 CONFLICT 都是 0**，因此这两个标签无法评估。系统对 28/60 给出 “未判断”。初版审阅报告把没有执行的有效选择错写成 0%，修正版已更正，旧文件保留供审计。

决定：Graph、压缩、自适应和时间优先都不晋级 Level C/D，默认关闭；Graph 浏览面板保留为显式开启的展示功能。最终实验只比较 H 和 D 两组，所有附加模块关闭。

E21 40 题 query-specific 有效证据选择诊断（11-04）

动机：E20 的关系审阅只回答了 “一对 Memory 之间是什么关系”，没有回答 “在这道题里应该用哪几条”。后者才是 Dynamic 解析阶段要做的事。

设置：按身份哈希从每个开发对话固定取 10 题，共 40 题，不依赖预测、运行状态或分数。两位独立 AI 各审 20 题，不看预测、存储关系、生成答案和 QA 标注；参考先冻结，之后才评分。参考结果为 30 条充分、9 条不足、1 条冲突；25 题可评分，15 题因参考本身有歧义单列。

结果：在 25 道可评分题上，严格有效集合完全一致 18/25（72%），集合 Macro-F1 0.854，状态判断 23/25（92%）。不一致的情况是 4 题多选、1 题少选、2 题缺失预测。各对话的严格集合一致数为：conv-26 7/9、conv-30 1/6、conv-41 6/6、conv-42 4/4。

决定：这是对历史预测的诊断，没有生成新模型的预测。它说明解析阶段在多数可判定题上选对了集合，在部分对话上明显偏弱；样本量不足以给出总体准确率。

4.5 阶段五：冻结评测（11-04 至 11-05）

E22 Level C v1：开发集固定 200 项真实实验（11-04）

动机：E20 之后只剩 H 和 D 两个候选。用一个新的固定样本，在真实调用下比较这两组。

设置：按 SHA 顺序从四个开发对话各取 20 道普通题和 5 道诊断题，共 100 题，两组共 200 项，题单不按候选表现挑选。四份开发 Build、Prompt、配置和样本身份都绑定在冻结计划里。所有生成都冻结并通过终态审计后，才读取开发集的 gold。这一阶段的独立硬上限为 1,500 次请求 / USD 130.98，messages 字节上限 160,000，完整解析输入预算沿用 96,000；所有附加模块关闭。

结果：

分层	策略	成功 / 计划	完整分母 F1	仅成功项 F1
普通	Hybrid	80/80	0.399883	0.399883
普通	Dynamic	41/80	0.228329	0.445521
诊断	Hybrid	20/20	0.456503	0.456503
诊断	Dynamic	10/20	0.293302	0.586604

普通题的 D−H 为 −0.172，区间 [−0.257, −0.093]：17 题提高、35 题退化、28 题不变。诊断题为 −0.163，区间跨零。

失败：49 项失败全部来自 Dynamic。其中 35 项是 `physical_request_policy_rejected`（消息超过 160,000 字节），14 项是 `complete_resolution_input_budget_exceeded`。最早的两例按保存的 Trace 离线重建，首次消息分别为 177,571 和 161,788 字节，都没有发出解析请求。我没有改上限、截断证据或补跑。

来源盲审：两名审阅者分别通读 conv-26/30 的 788 轮和 conv-41/42 的 1,292 轮原文，再审各自负责的 100 个匿名答案；461 条逐字引文全部核验通过。在已运行成功的答案上，来源支持为 Hybrid 64/92、Dynamic 41/49；错误人物 0/151；错误时间 Hybrid 4/94、Dynamic 0/50。

成本：421 次物理请求全部返回完整 usage。按已报 usage 计，Hybrid 的峰价上界为 USD 0.230、Dynamic 为 USD 0.940，比值为 4.1。保守预约合计 USD 19.31。

诊断：Dynamic 在共同成功的 41 道普通题上 F1 为 0.446，高于 Hybrid 的 0.368。但这个子集是按运行成功筛出来的，有选择偏差。完整分母上的负差几乎全部来自输入限制失败，失败是在本地被拦截的，模型并没有答错。

决定：本轮不晋级 Level D/E，也不改变生产默认。先解决完整解析输入与预算之间的兼容问题，再决定是否申请新的生成实验。

E23 Level C input v2（11-04）

动机：E22 的失败全部来自两个输入上限。用同一批题，只放宽这两个上限，看 Dynamic 在运行可靠的前提下能否超过 Hybrid。

设置：先离线重建全部 100 项的首次解析请求：最大消息 480,456 字节、145,670 个正则 token。据此把字节上限从 160,000 调到 640,000，完整解析预算从 96,000 调到 192,000。如果只用 320,000 字节，100 项中只有 87 项能满足。所有新生成都关闭 thinking，不发送 `reasoning_effort`。新阶段的独立硬上限为 1,500 次请求 / USD 346.98。

结果：

分层	策略	成功 / 计划	完整分母 F1
普通	Hybrid	79/80	0.401172
普通	Dynamic	80/80	0.444702
诊断	Hybrid	20/20	0.434314
诊断	Dynamic	20/20	0.473472

普通题的 D−H 为 +0.044，区间 [−0.008, +0.095]：27 题提高、14 题退化、39 题不变。四个对话的差值都为正：+0.074、+0.039、+0.052、+0.009。诊断题为 +0.039，区间 [−0.056, +0.135]。

唯一的失败来自 Hybrid：回答阶段三次输出都没有给出证据状态字段，终态为 `invalid_output`。

来源盲审：在两组都运行成功且来源判断确定的 60 个普通题配对中，2 对改善、1 对退化、57 对不变，平均差 +0.017，区间跨零。引用支持在普通 61 对和诊断 14 对中的差值都是 0。

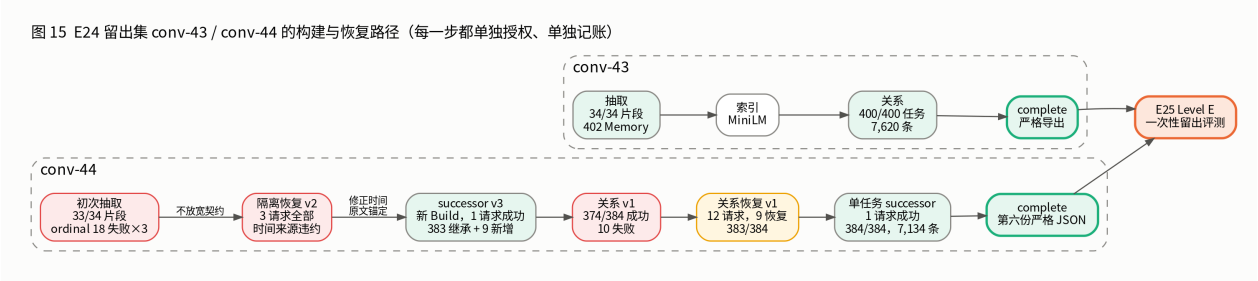
成本：522 次请求，usage 全部已知。按已报 usage 计，Dynamic 的峰价上界为 USD 2.353，Hybrid 为 USD 0.233，**比值为 10.1**。普通题单题 p50 延迟为 8.8 s 对 2.5 s。

诊断：输入失败消失后，F1 的方向翻转为正，但区间仍跨零；按来源审阅看，同题改善几乎为零。Dynamic 用十倍的费用换来了一个统计上无法与零区分的 F1 差值。

决定：最终 Level E 固定为 H、D 两组，所有附加模块关闭，input v2 的上限不变。Hybrid 作为默认候选，Dynamic 作为显式可选候选。这是候选建议，不是生产默认的切换。

E24 留出集 conv-43/44 的构建与多轮恢复（11-04 至 11-05）

动机：Level E 需要两份完整的留出 Build。构建只读取原始对话，不读取留出集的 QA、证据或答案。



conv-43：抽取 34/34 片段，402 条 Memory；真实 MiniLM 索引；关系阶段 400/400 任务成功，7,620 条关系标签，共 408 次物理请求，其中 7 次 transport unknown，按预约计入。之后完成 complete 并严格导出。

conv-44：一共走了五步，每一步都单独准备计划、经非作者复核，并由我明确批准独立的调用与金额上限，额度不跨阶段转移：

1. **初次抽取**:33/34 片段,383 条 Memory。第 18 个片段三次都报 `extraction_time_expression_required`：模型给出的时间表达没有出现在所引锚点的原文里。
2. **隔离恢复 v2**：3 次请求，全部仍然违反时间来源契约，没有新增 Memory。我没有放宽校验，也没有清空时间字段。
3. **successor v3**：修正的是时间表达的原文锚定方式，契约本身不变。新建 Build，首次请求即通过；383 条继承加 9 条新增，共 392 条。
4. **关系 v1**：384 个任务中 374 成功、10 失败，共 6,973 条关系。失败任务各用尽 3 次尝试：8 个是 `known_source_required`(引用了不在已知来源中的 ID),2 个是 `same_state_dimension_required`。关系标签分布为：未确定 6,769、RETAIN 106、UPDATE 91、SUPERSEDE 5、CONFLICT 2。
5. **关系恢复 v1，再加一个单任务 successor**：恢复阶段 12 次请求，10 个失败任务中 9 个恢复，达到 383/384；剩下的 1 个任务在单独批准后 1 次请求成功，达到 384/384，共 7,134 条合法关系。392 条 Memory 的 CurrentState 投影重新计算后完全一致，之后在新的本地副本中完成 complete 并严格导出第六份 JSON。

每一步都保留原有的成功任务、关系和调用记录，逐行不变，只在新副本中追加。conv-43/44 的共同 Build 覆盖七个构建和恢复阶段，共 920 次请求，预约 USD 45.04，已报峰价上界 USD 6.61。

决定：两份留出 Build 都达到 complete，进入 E25。

E25 Level E 独立留出评测（11-05）

动机：在全部策略、实现、模型、Prompt、参数、评分脚本和预算都锁定之后，进行唯一一次留出评测。

设置：conv-43/44 的 400 题 × H/D，共 800 项。实现 commit、系统锁和计划 SHA 在读取留出题正文之前就已固定。输入上限为 640,000 字节，完整解析 192,000，输出 32,768；每个操作最多 3 次模型尝试，HTTP 层不重试，thinking 关闭。生成冻结后，根代理和非作者终态审计都通过，之后才读取 gold 评分。这一阶段的独立硬上限为 6,000 次请求 / USD 1,387.93。

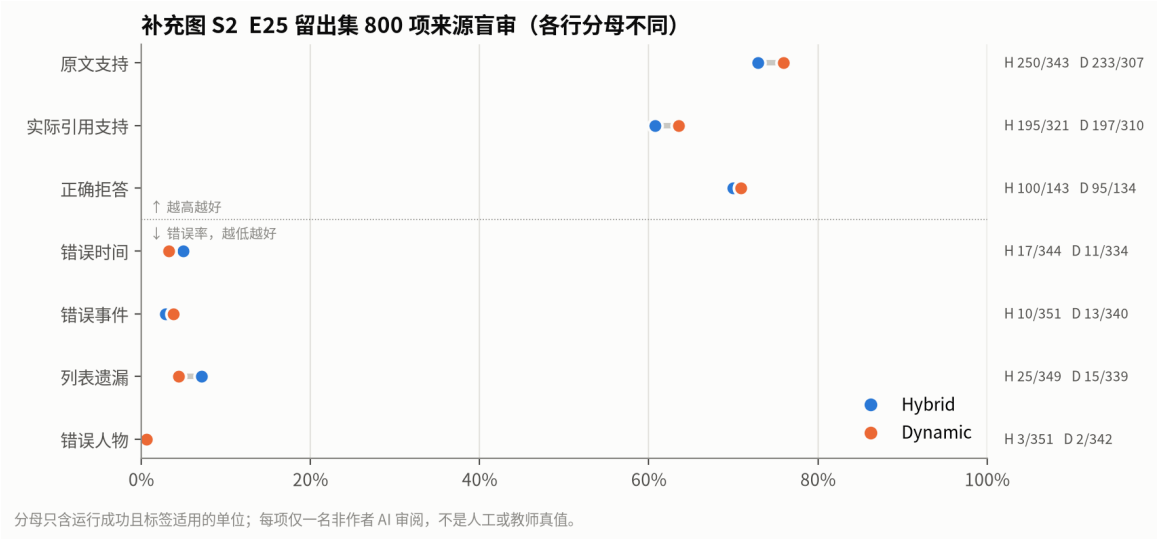
结果：

范围	每组题数	H 成功	D 成功	H 完整分母	D 完整分母
类别 1–4 token F1	301	299	295	0.402606	0.409151
类别 5 字面拒答	99	95	94	0.858586	0.808081

范围	每组题数	H 成功	D 成功	H 完整分母	D 完整分母
混合规则均值（不是事实正确率）	400	394	389	0.515461	0.507886

- **类别 1–4**：D−H = +0.0065，区间 [−0.020, +0.034]；60 题提高、56 题退化、185 题不变。
- **类别 5**：D−H = −0.051，区间 [−0.101, 0]；1 题提高、6 题退化。
- **按对话**：两段对话的混合差值分别为 −0.021 和 +0.013，区间都跨零。
- **类别 2（时间）**：差值 +0.049。这是探索性结果，没有做多重比较校正，不能据此宣称提升。

来源盲审：三名没有参与本次生成实现的 AI 分区审阅了全部 800 项。每人先通读对应的完整原文，再核对答案、解释、全部引用和拒答，共保存 1,796 条逐字引文。审阅包隐藏组别、gold、分数和解析 Trace。17 个运行失败标为 N/A。



条件配对（两组都成功、且标签明确适用的题）：原文支持在 297 对中 28 对改善、18 对退化、251 对不变，差值 +0.034，区间 [−0.010, +0.078]；引用支持 31 对改善、23 对退化；正确拒答 0 对改善、2 对退化。错误时间、列表遗漏的差值为负（即 Dynamic 的错误更少），但区间分别跨零或触零。

来源 Recall：见图 9。Dynamic 的初始与扩展覆盖和 Hybrid 几乎相同；经过有效证据解析后，Recall@20 从 0.725 降到 0.537，交付覆盖低于 Hybrid 的 0.719。

失败与费用：Hybrid 394/400 成功，Dynamic 389/400；17 个失败项中 8 个为 `invalid_output`，9 个是末段遇到 HTTP 402（账户余额不足）。安全元数据显示共有 18 次 402 请求，都缺少 usage，预约不释放、也不按零成本处理。一次执行结束后，即使额度恢复，也不自动重启，没有重跑。

查询范围	Hybrid	Dynamic	合计
物理请求	851	1,261	2,112
usage 未知的请求	8	10	18
保守预约，USD	36.2805	69.1711	105.4516575
已报 usage 峰价上界，USD	0.8706	6.8800	7.7506
单题 p50 / p95，s	2.37 / 3.94	8.31 / 12.40	—
每个成功项的已报输入 tokens	6,604	51,849	—

Dynamic 与 Hybrid 的已报峰价比约为 7.90，预约比为 1.91。两者口径不同，都不是实际账单的比值。

结论: 在锁定配置下的一次留出评测中, 答案指标和来源审阅都没有显示 Dynamic 有稳定改善, 而 Dynamic 的查询费用约为 Hybrid 的 7.9 倍。留出结果已经曝光，此后的任何修复或重跑都只能标为回归测试，不能再称为同一次独立测试。

5 跨实验综合

本章把前面分散在各个实验里的结果按研究问题重新组织。图中的每一行都来自单个实验内部的比较；跨实验只看方向，不比较绝对数值。

5.1 实验谱系

图 3 实验谱系：每个实验由哪个观察引出（虚线为跨阶段）

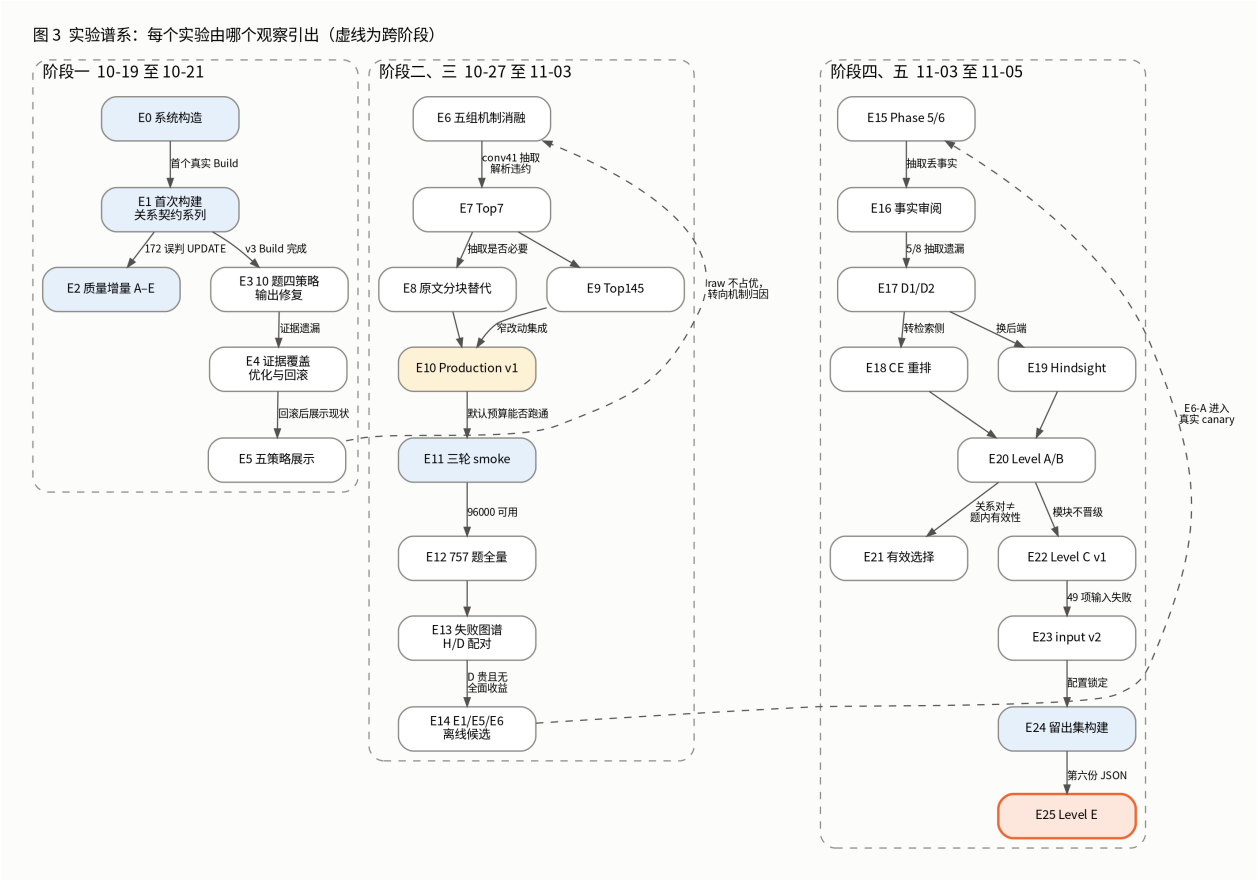
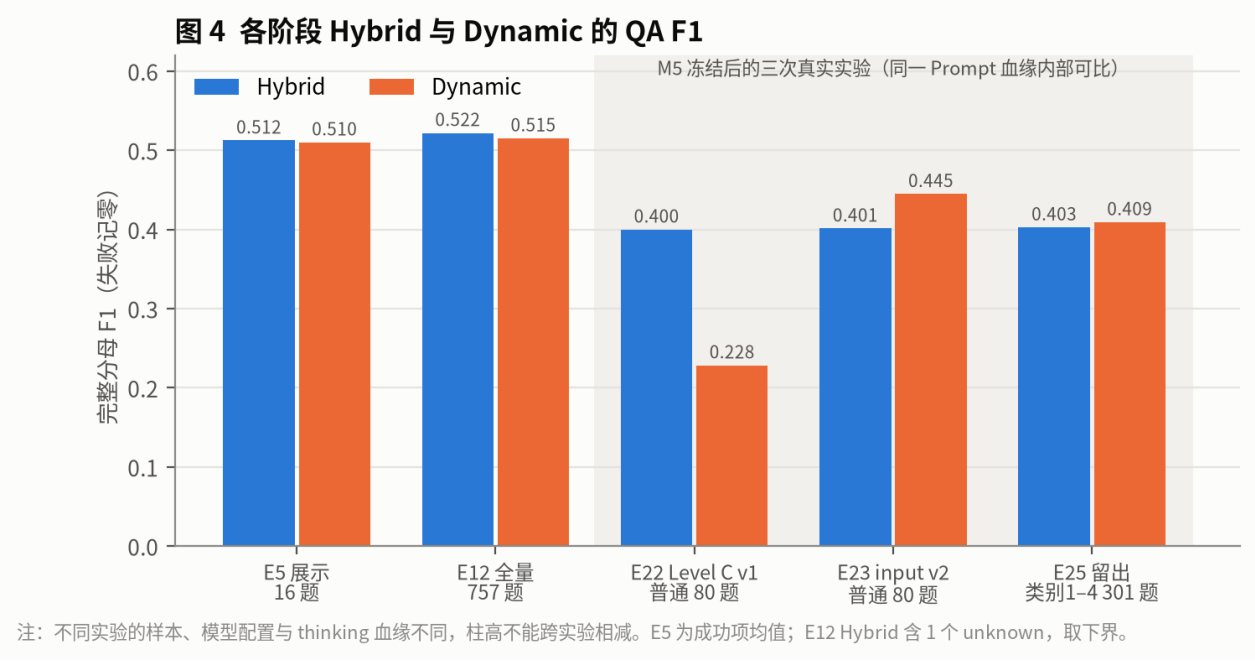


图 3 把 26 个实验单元按 “上一步暴露了什么” 连起来。整个过程有三次明显的转向:

1. **E5 → E6**：原文兜底不占优之后，问题从 “选哪种策略” 转向 “Dynamic 的哪个机制在起作用”。
2. **E13 → E14**：完整分母配对显示 Dynamic 贵且没有全面收益，研究重心转向降本和减少输入失败。
3. **E15 → E16 → E17**：两道 canary 题都把错误追溯到抽取阶段，后续实验转向定位证据损失，并从检索侧（E18）和外部后端（E19）寻找替代方案。

5.2 RQ1：答案质量



注：不同实验的样本、模型配置与 thinking 血缘不同，柱高不能跨实验相减。E5 为成功项均值；E12 Hybrid 含 1 个 unknown，取下界。

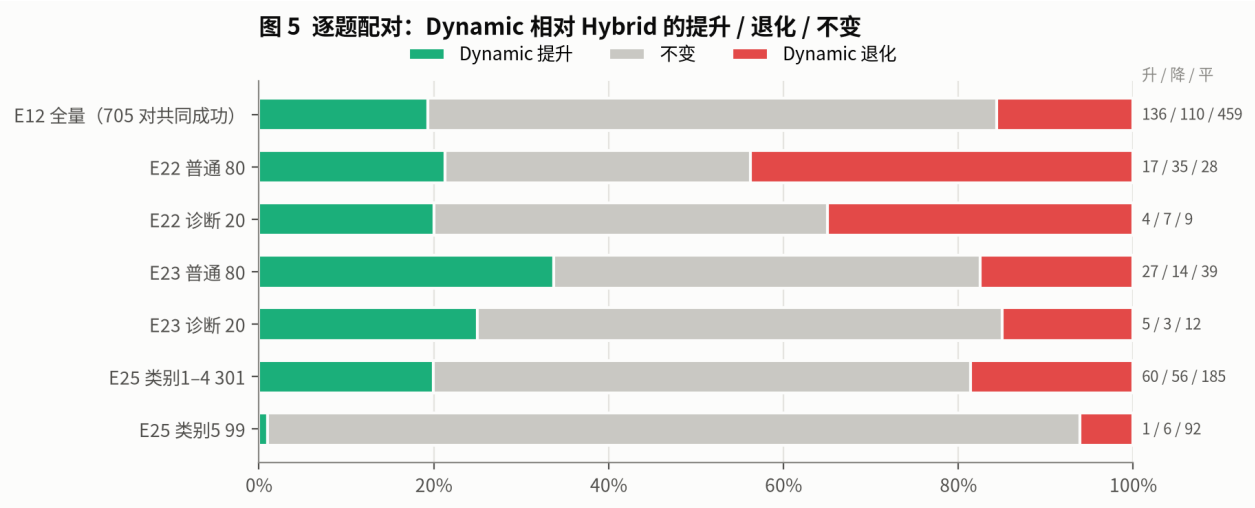
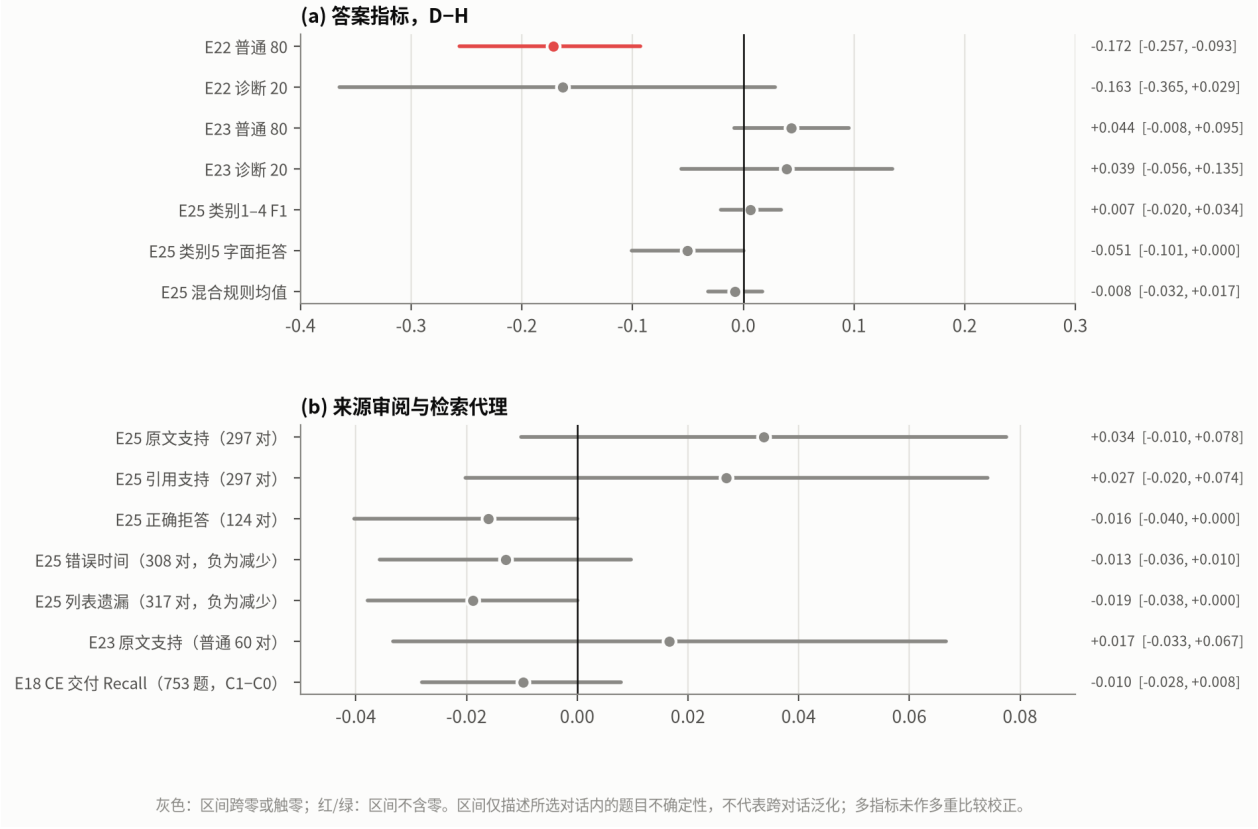


图 6 配对差值与 95% bootstrap 区间



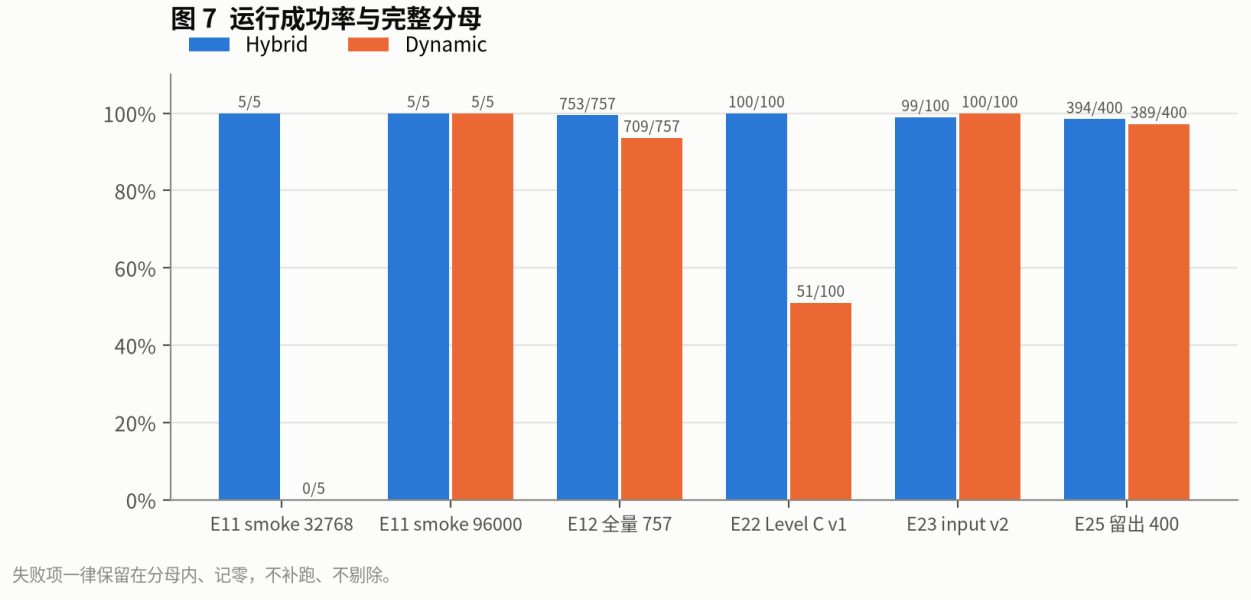
实验	样本	H 完整分母	D 完整分母	D−H	95% 区间	是否跨零
E5	16 题，已曝光	0.512	0.510	−0.002	未计算	—
E12	757 题，已曝光	[0.522, 0.523]	0.515	约 −0.007	未计算	—
E22	普通 80 题，已曝光	0.400	0.228	−0.172	[−0.257, −0.093]	否（负）
E23	普通 80 题，已曝光	0.401	0.445	+0.044	[−0.008, +0.095]	是
E25	类别 1–4 共 301 题，留出	0.403	0.409	+0.007	[−0.020, +0.034]	是

E22、E23、E25 的附加模块全部关闭，但 E22 到 E23 同时改变了输入上限和 resolution thinking（low → disabled），不能作单因素归因。E22 到 E23 的差值从 −0.17 翻转为 +0.04，与运行失败大幅减少同时出现。E23 到 E25 换成了留出集，差值从 +0.044 缩小到 +0.007。开发集上看到的正向趋势，在没有被反复诊断过的数据上大部分消失了。

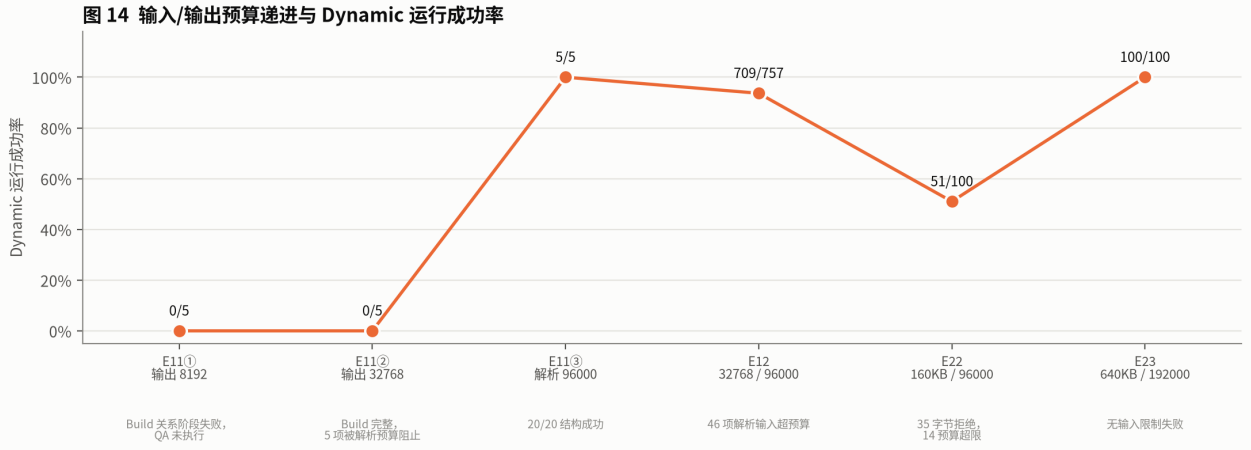
来源盲审给出的结论相同：E23 的同题来源支持 2 对改善、1 对退化；E25 为 28 对改善、18 对退化，区间都跨零。

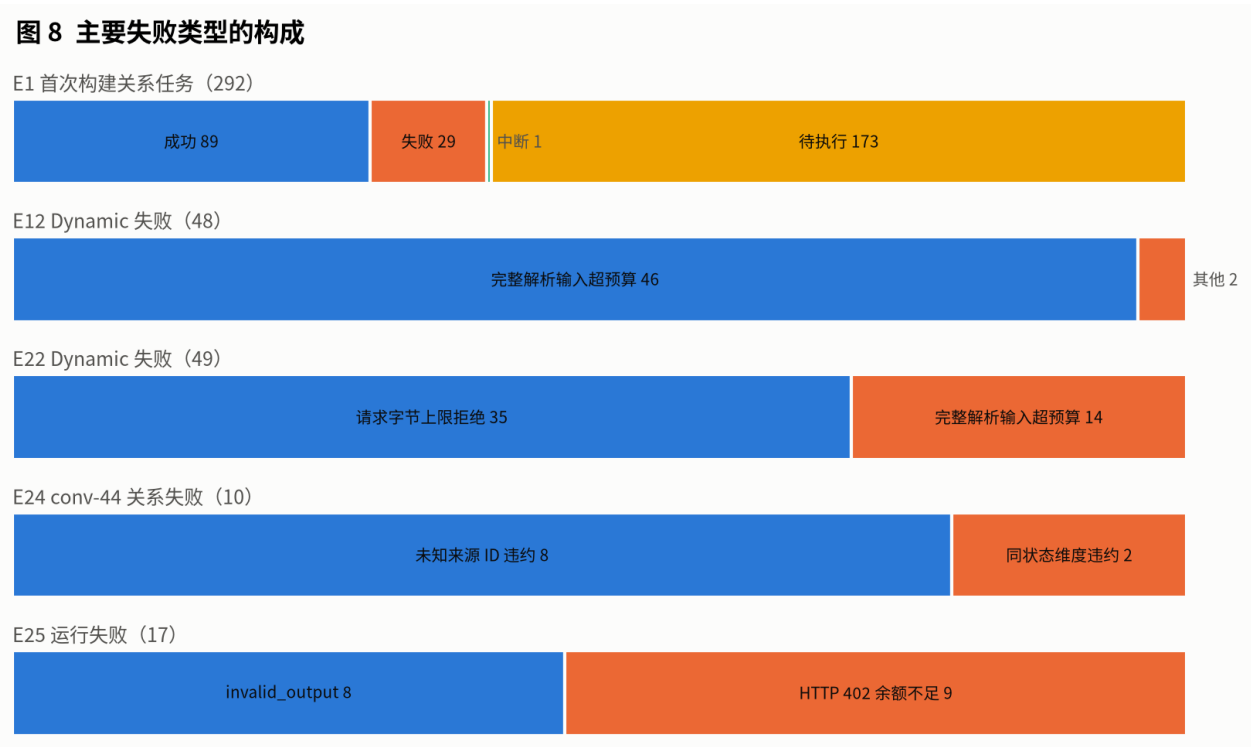
回答：现有证据不支持 “Dynamic 稳定优于 Hybrid”。

5.3 RQ2：可靠性与成本



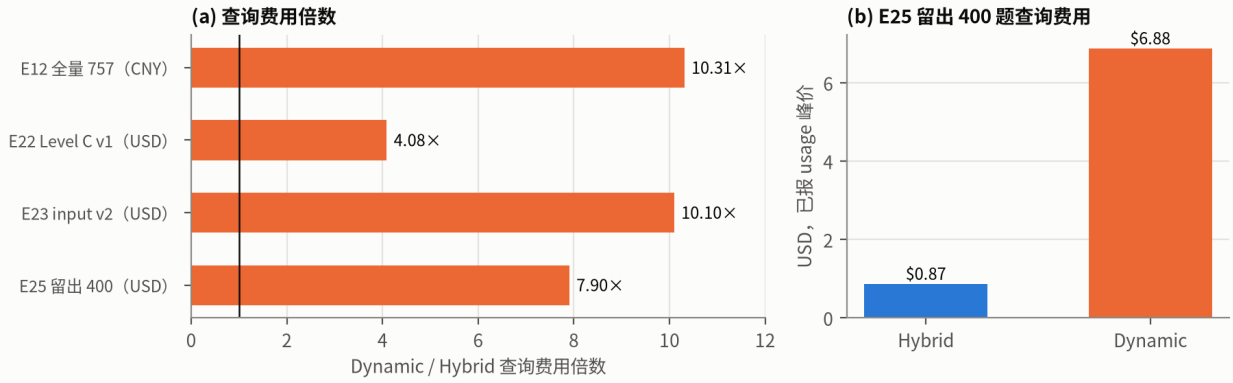
失败项一律保留在分母内、记零，不补跑、不剔除。





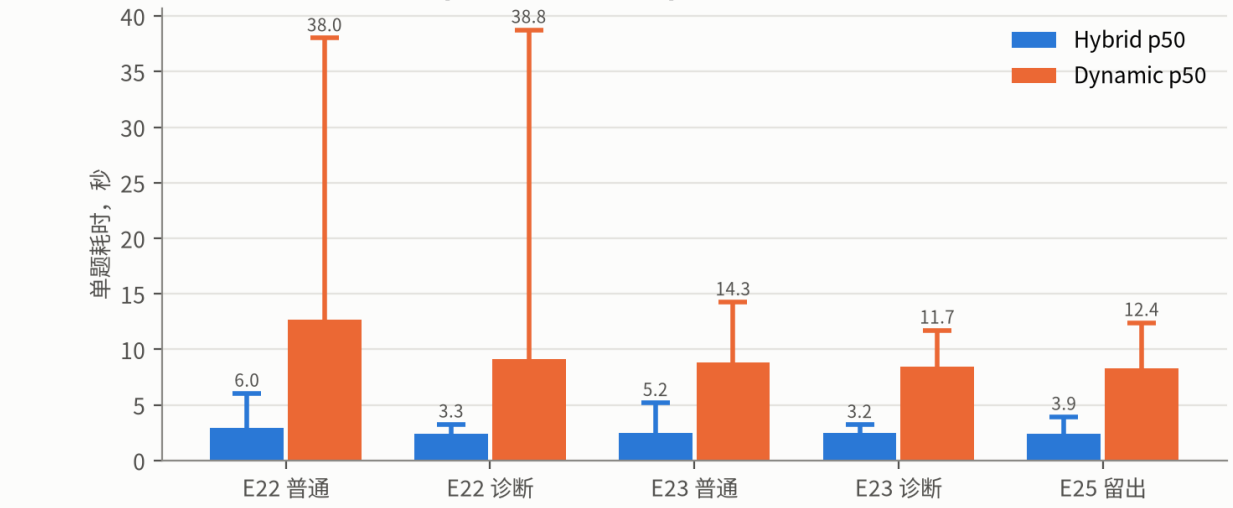
Dynamic 的失败主要不是因为模型答错，而是完整解析输入被预算或字节上限挡住。这类失败在本地被拦截，请求没有发出（E11②、E12、E22）。每一次放宽上限（E11③、E17、E23）都能消除这类失败，代价是更长的输入和更高的费用。

图 11 查询成本



均按 provider 报告 usage 与峰时 cache-miss 单价折算，不是实际账单；不含 Build 费用。

图 12 单题延迟：柱为 p50，竖线顶端为 p95



串行实验、共享工作站测量，包含失败项；不作为服务吞吐承诺。

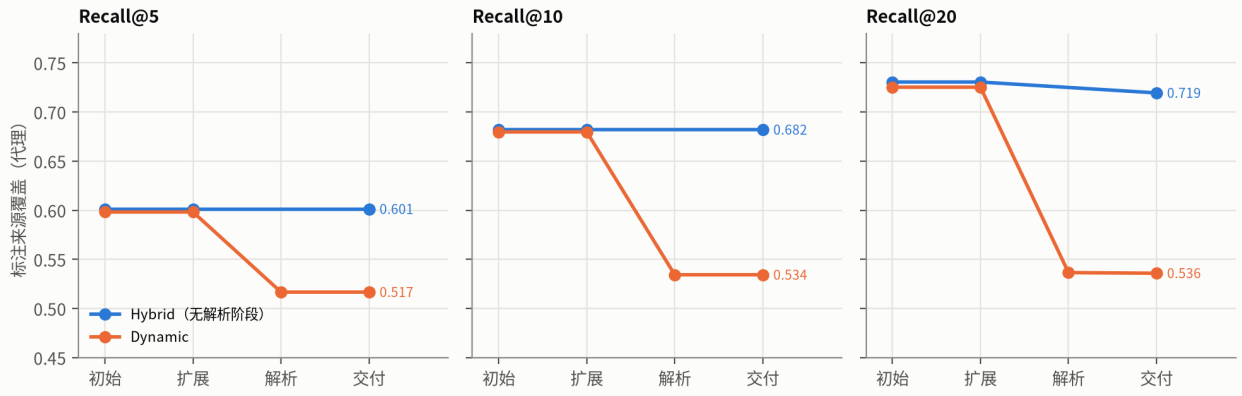
实验	D/H 查询费用比	D/H 单题 p50 比	口径
E12	10.31	—	峰时估算，CNY
E22	4.08	4.36（普通题）	已报 usage 峰价，USD；49 项失败在本地被拦截，没有产生费用
E23	10.10	3.53（普通题）	已报 usage 峰价，USD
E25	7.90	3.51	已报 usage 峰价，USD

E22 的费用比偏低，是因为将近一半的 Dynamic 请求没有发出。去掉这个因素后，Dynamic 稳定地比 Hybrid 贵 8–10 倍，慢约 3.5 倍。E25 中每个成功项的已报输入 tokens，Dynamic 为 51,849，Hybrid 为 6,604，相差 7.9 倍。

回答：Dynamic 多出的解析步骤带来约 8–10 倍的查询费用和约 3.5 倍的延迟。输入上限足够时，它的运行可靠性与 Hybrid 相当（E25：389 对 394）。

5.4 RQ3：证据损失的位置

图 9 E25 留出集：来源覆盖在流水线各阶段的变化



Dynamic 的有效证据解析使标注来源覆盖下降约 0.08–0.19；被删来源是否确实不适用于问题，未单独测量。

各个实验的证据从不同侧面指向同一组结论：

- **抽取**：E1 的案例 172，E6 的 conv-41 时间锚点，E15 的 D17:25/26，E16 中 8 例错误拒答里的 5 例，E19 中 Qwen3 的多处遗漏，E24 中 conv-44 第 18 片段反复失败。可以确认的事实丢失大多发生在抽取阶段。
- **检索与扩展**：E16 的共同遗漏来源链中，21/35 是初始召回疑似缺口。但 E17（D1 原文锚点）和 E18（Cross-Encoder）都没能把它们稳定补回来，E20 的 Graph 扩展也没有提高交付覆盖。
- **有效证据解析**：E25 中，Dynamic 的解析使标注来源覆盖下降 0.08–0.19（图 9），但答案 F1 没有下降。这有两种可能的解释：被删掉的来源确实不适用于本题；或者回答模型在缺少它们时仍能作答。两者无法区分，因为题内有效性的准确率只在 E21 的 25 道可评分题上测过（72% 严格一致）。
- **关系标签的分布**：E20 的 60 个参考关系中，SUPERSEDE 和 CONFLICT 都是 0；E24 中 conv-44 的 6,973 条关系里，6,769 条为 “未确定”，SUPERSEDE 只有 5 条，CONFLICT 2 条。Dynamic 设计时针对的 “旧状态被新状态替代”，在这批对话里很少出现。这可能是它难以产生增益的一个结构性原因，但我没有专门检验这个假设。

回答：损失分布在多个阶段，能确认的部分以抽取为主。Dynamic 只作用于检索之后的环节，抽取阶段丢掉的事实它补不回来。

5.5 候选的最终去向

图 16 候选的最终去向



这次探索最终留下的，主要是工程约束，而不是质量改进：持久恢复、完整失败分母、来源绑定、输入预算保护、安全诊断码和多版本严格导出。在 E7–E21 中提出的二十余个质量候选里，只有 reader v2 和选择性前文（降本 28.3%）在已知题上稳定成立，两者都只保留为可选项。其余候选要么在同题对照或新边界上不成立，要么证据不足、暂时搁置。

6 实验工程方法

这一章整理在 18 天里逐步形成、后来每个实验都遵守的做法。很多做法是被具体失败逼出来的，所以每条都注明起点。

6.1 完整失败分母

规则：运行失败、预算拒绝、超时都留在分母里记零；unknown 给出上下界；“仅成功项” 的分数单独标注，不作为主结论。

起点：E3 初轮里，Dynamic 9/10 的成功数和后来的 F1 是两回事；E12 中 Dynamic 在成功子集上均值较高（0.550 对 0.525），计入 48 项失败后反而略低。E22 是最极端的例子：仅成功项 Dynamic 领先 0.077，完整分母落后 0.172。如果只报成功子集，结论方向会完全相反。

6.2 先冻结，后评分

规则：题单、策略、Prompt、配置和预算在生成之前冻结并记录 SHA；所有生成结束、终态审计通过之后，才读取 gold。语义审阅同样先封存审阅结果，再揭盲。

起点：E6 的协议规定，正式运行后改动题单或 Prompt 会改变比较身份。E7 的语义复核首次采用 “冻结后揭盲”。E25 把这一点做到最严：系统锁先于留出题正文读取，评分是生成结束后的单独操作，看过结果后不再调参。

6.3 每个付费阶段单独授权、单独记账

规则：每个付费阶段都有独立的次数、金额和时间上限，由我明确批准。每次请求发送前持久化一个预约槽位；结果未知的请求按全额预约保留，不释放、不自动重发；阶段之间的余额不转移；一次执行结束后，即使还有余额，也不自动追加。

起点：E1 的独立回放先批 6 次，再批 16 次，每轮各用独立的 SQLite 账本。E11 的三轮共用一个 ¥40 / 500 次的累计上限，截止时间不因重启而重置。E24 中 conv-44 的五步恢复各自批准，每一步都先免费准备、经非作者复核，再申请额度。E25 末段遇到 HTTP 402 后，按规则不重启。

6.4 新配置就是新身份

规则：配置是 Build 身份的一部分；修改配置必须新建 Build 或 Run，不能在原地修改，也不能把不同身份的结果拼接成一个分数。补充运行和修复运行不回填原分母。

起点：E11 的三轮各自新建身份；E12 的补充 Run 和修复 Run 与原 3,028 项分开保存；E24 的 successor Build 只在新副本中追加，原有成功任务和关系逐行保留。

6.5 不靠放宽校验来 “修复”

规则：模型输出违反契约时，可以修改模型可见的指令，或把校验规则与 Prompt 共用同一份定义；不能放宽 schema、在后处理中替模型改标签、截断证据或硬编码案例 ID。

起点：E1 中，同状态维度、重复证据 ID、标签前提三类问题，都是通过让模型看到校验器实际执行的规则解决的；案例 172 的语义错误则没有被 “修” 掉。E24 中 conv-44 第 18 片段的时间契约始终没有放宽，最终靠修正锚定方式通过。

6.6 区分 “已证明” 与 “仍未证明”

规则：每个实验的记录都分开列出已经证明的结论和仍未证明的内容。来源 ID 合法不等于来源支持结论；结构通过不等于语义正确；离线 Mock 通过不等于真实可用；局部改善不等于总体收益。

起点：Top7 的记录表从一开始就有 “本轮改动 / 仍未证明” 两列。E20 的初版审阅把没有执行的有效选择错写成 0%，后来更正，旧文件保留供审计。

6.7 复核身份分开标注

规则：作者代理的自查、非作者 AI 审阅、格式与哈希核验、人工复核，各自单独标注，不合并为 “已验证”。每项只有一名审阅者时，不报告一致性指标。

起点：E5 的来源审阅属于开发助手自查；E15 第一次复核重试没有形成有效产物，因此有效的非作者审阅数被如实记为 0；E16、E22、E25 的审阅者都明确不参与对应的生成实现。

6.8 用 AI 编码代理推进实验

实验的实现、运行和整理由 AI 编码代理在上述规则下完成。实践中，规则需要写进执行代码和工具，不能只写在文档里：预约账本、身份哈希检查、“终态审计通过才能读 gold” 的门槛，都在执行器里强制执行。代理也会犯错，例如初版审阅里的 0% 写错、测试读取任务列表时只取了默认的前 20 项、一次命令引用了不存在的测试文件。这些错误都被保留在记录里，之后另行更正。

7 局限与有效性威胁

- **样本量**：留出集只有两段对话、400 题；bootstrap 区间只描述这两段对话内部的题目不确定性，不支持对话级泛化，也不代表教师的隐藏评分集。
- **开发集曝光**：E5–E23 都在已经被反复诊断过的四段开发对话上进行，其中的正向结果可能包含过拟合。
- **语义真值**：所有语义判断都来自 AI 审阅者，每项通常只有一名，没有人工双审一致性；文字风格可能泄露组别，因此不能保证严格盲法。
- **模型版本**：`deepseek-flash` 是可变别名，无法证明整个实验期间的服务端权重相同。
- **thinking 血缘**：E22–E25 的新生成关闭 thinking，但开发集 Build 的关系判断是在 high thinking 下构建的，最终结果不是 “全链路关闭 thinking” 的成绩。
- **指标**：token F1 对改写和措辞很敏感；来源 Recall 是代理指标，不等于事实召回；题内有效选择的准确率只在 25 道题上测过。
- **费用**：全部是预约或已报 usage 的峰价折算，没有读取实际账单；E25 有 18 次请求的 usage 未知。
- **记录完整性**：仓库之外的个人探索和缺失的临时文件无法证明已经穷尽；没有找到记录的内容，本文标注为证据缺失，不补写。
- **数据披露**：本文只报告聚合数字和改写过的案例，不引用 LoCoMo 原文、留出集答案或 provider 原始响应。

附录 A 实验总表

编号	日期	内容	真实调用	样本 / 分母	核心结果	去向
E0	10-19	系统构造与工程验证	0	各模块离线测试	112 项浏览器/CI 通过	工程基线
E1	10-20	首次构建与关系契约系列	220 + 6 + 4 + 9 + v5 Build + 25	292 关系任务；回放 3 / 2 / 3 任务	89/29/1/173；三类契约问题修复；172 语义关卡失败	契约修复保留，完整重建阻止
E2	10-20	质量增量 A–E	26	合成探针	局部改善；172 仍误判 UPDATE	工程实现保留，默认 expanded
E3	10-20–21	10 题四策略 + 输出修复	初轮 + 98	40 项	24/40 → 40/40；D 0.154→0.334	回答契约保留
E4	10-21	证据覆盖优化与回滚	30 项 A/B	30 项	无稳定提升	P0/P1 回滚
E5	10-21	五策略现状展示	307	100 项 QA + 40 Recall + 10 关系 + 20 审阅	H 0.512 / D 0.510 / 兜底 0.400	否定原文兜底更优
E6	10-27–29	五组动态机制消融	107+ / 14 / 14 等	计划 1,080	未完成；conv-41 抽取反复失败	停止
E7	10-29	诊断码细化与 Top7	9 + 48 + 104 + 48	960 合成；6 / 8 / 8 项	reader v2 完成语义 2/8→6/8；关闭 thinking 3/8	reader v2 可选；七父项未验收
E8	10-29–30	原文分块替代	78	计划 80	必需事实 64 / 48 / 70（/78）	拒绝替换
E9	10-29–30	Top145	96 + 249 + 86 + 56	已知题 + 12 边界	选择性前文 −28.3% token，质量 8/8	窄候选可选
E10	10-31–11-01	RC1/RC2 与 Production v1	334	168 pipeline	selective 节省 15.8% < 20%	31 项工程采用；F01/F03 不采用
E11	11-01	三轮预算 smoke	84 + 322 + 40	每轮 20 项	0 → 15 → 20 项成功	研究参数可用
E12	11-01–03	757 题全量基线 + 补充与修复	全量 + 59 + 8	3,028 项	H [0.522, 0.523]；D 0.515；D 失败 48	原基线保持
E13	11-03	失败图谱与配对	0（AI 审阅）	705 对	136/110/459；费用 10.3 倍	不默认采用 D
E14	11-03	E1 路由 / E5 缓存 / E6-A	0	757 题	路由覆盖 0；E6-A 输入 −34.3%	E6-A 进入 canary
E15	11-03	Phase 5 canary 与 Phase 6	8	2 对	prompt −26.1%；语义不确定	E6-A HOLD；E7 关闭

编号	日期	内容	真实调用	样本 / 分母	核心结果	去向
E16	11-03	Phase 7 事实审阅	0（AI 审阅）	80 题 × 2	错误拒答 D 8 / H 11；5/8 抽取遗漏	归因到抽取
E17	11-03	D1 / D2 离线消融	0	757 / 711	遗漏来源恢复 3/35	HOLD
E18	11-04	Cross-Encoder 重排	0	753 题	交付 Recall −0.010	HOLD
E19	11-04	Hindsight 与 Qwen3 0.6B	0（本地）	合成 11 事实	来源链通过；逐事实轮次不支持	Hindsight HOLD；小模型配置 REJECT
E20	11-04	Level A/B、PropMem、关系审阅	0	757 × 6；60 关系对	模块无交付增益；关系 50/60	模块默认关闭；PropMem REJECT
E21	11-04	题内有效选择诊断	0	40 题，25 可评分	严格集合 18/25	诊断
E22	11-04	Level C v1	421	200 项	普通 D−H −0.172；D 失败 49	不晋级
E23	11-04	Level C input v2	522	200 项	普通 D−H +0.044，跨零；费用 10.1 倍	锁定 H/D 两组
E24	11-04–05	留出集构建与恢复	920	2 段对话	conv-44 经五步达到 384/384	两份 complete
E25	11-05	Level E 留出评测	2,112	800 项	类别 1–4 D−H +0.007，跨零；费用 7.9 倍	零结果

附录 B 失败类型目录

失败类型	所在阶段	含义	出现的实验	处理方式
`same_state_dimension_required`	关系	RETAIN / SUPERSEDE / CONFLICT 的两端不在同一状态维度	E1、E24	规则写进 Prompt（relations-v2）
`reason_and_unique_evidence_required`	关系	旧的联合错误码，无法区分两种原因	E1	拆成下面两个错误码
`nonblank_reason_required` / `unique_evidence_required`	关系	理由为空 / 证据 ID 重复	E1	增加去重指令（relations-v3）
`factual_resolution_required`	关系	旧事实与新非事实之间的标签前提不满足	E1	校验器与 Prompt 共用标签函数（relations-v5）

失败类型	所在阶段	含义	出现的实验	处理方式
`known_source_required`	抽取、关系	引用了不在已知来源中的 ID	E11、E24	有限重试；不放宽
`extraction_time_expression_required`	抽取	时间表达不在所引锚点原文中	E6、E24	修正锚定方式；契约不变
输出长度截断	关系	输出达到上限	E1、E11	输出上限 8,192 → 32,768，新身份
`complete_resolution_input_budget_exceeded`	解析	完整候选超过解析输入预算	E11、E12、E22	预算 24K → 96K → 192K，新身份
`physical_request_policy_rejected`	解析	消息超过本阶段字节上限	E22	上限 160,000 → 640,000 字节，新阶段
`answer_evidence_status_required`	回答	回答缺少证据状态字段	E23	记为 `invalid_output`，不补跑
`invalid_output`（结构）	各阶段	模型输出没有通过 schema 或领域校验	E3、E6、E25	计入分母；保存诊断码
`model_http_error`（HTTP 402）	传输	账户余额不足	E1、E12、E25	停止；预约保留；不自动重启
`transport_unknown`	传输	请求发出后结果未知	E6、E7、E24	按全额预约保留，不重发
OOM / 超时	构建	本地内存不足或请求超时	E12	分段显式恢复，不拼接
过度拒答	回答	证据已交付，回答仍然拒答	E16、E25	记录；没有自动修复
人物错绑	解析、回答	把事件归给了错误的人	E15	记录为语义风险，阻止 E6-A 扩大
Citation Failure	回答	引用 ID 合法，但不支持结论	E12、E13	单独标注；scorer 满分不代表引用正确

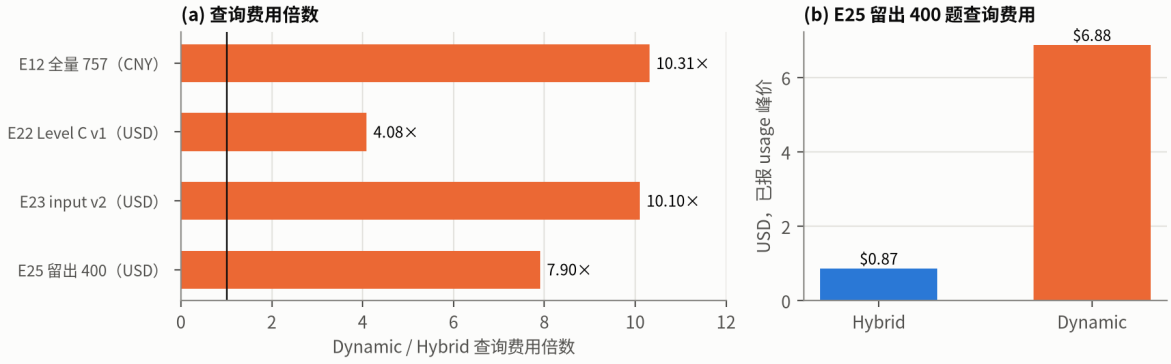
附录 C 成本表

所有金额都不是实际账单。“预约” 是发送前按最坏情况扣减的额度；“峰价” 按已报 usage 和官方峰时 cache-miss 单价折算。表中各行口径不同，不能简单相加。

实验	物理请求	已报 tokens	预约	峰价	unknown
E1 同状态维度回放	6	54,475	—	未计算	0
E1 重复 ID 回放	4	50,068	—	未计算	0
E2 A–E	26	—	—	未计算	0
E5 展示	307	—	—	—	—
E6 A/D 四题	14	392,178	—	—	—
E6 解析契约修复 + 效果	4 + 10	214,263 + 129,252	—	—	—
E7 Top7 r2	103 已结算	448,646	—	—	1

实验	物理请求	已报 tokens	预约	峰价	unknown
E7 reader v2	48	99,193	—	—	0
E9 四批	96 + 249 + 86 + 56	276,723 + 593,616 + 212,852 + 242,531	—	—	0
E11 三轮 smoke	446	—	¥40 上限	¥21.46	0
E12 查询（757 × H / D）	—	—	—	H ¥9.60 / D ¥98.93	—
E15 canary	8	142,696 + 110,912	¥25 上限	¥0.627	0
E22 Level C v1	421	3,120,543	USD 19.31	USD 1.17	0
E23 Level C input v2	522	8,015,848	USD 27.81	USD 2.59	0
E24 留出集构建（7 阶段）	920	—	USD 45.04	USD 6.61	7
E25 Level E 查询	2,112	23,537,281	USD 105.45	USD 7.75	18
M5 十个付费阶段合计	3,975	—	USD 197.61	USD 18.12	25

图 11 查询成本



均按 provider 报告 usage 与峰时 cache-miss 单价折算，不是实际账单；不含 Build 费用。

E25 若各自独立部署一组（每组承担完整的共同 Build 成本，再除以 400 题），已报 usage 的单题成本为 Hybrid USD 0.0187、Dynamic USD 0.0337。这不包括未知 usage 和本地 embedding 的硬件成本。

附录 D 实验身份表

下表列出能够定位各实验原始记录的标识。Build 和 Run ID 取前 8 位；完整值、实现 SHA 和逐文件 SHA256 保存在原始实验记录中。

实验	标识类型	值
E1 首次构建	Build	`91f1f509`
E1 同状态维度回放	实验 ID	`ec886d1d`
E1 重复 ID 回放	实验 ID	`62c3c900`

实验	标识类型	值
E1 v5 冻结实现	实现 SHA256	`897f17a3`
E3 v3 Build	Build	`5c7699dd`
E3 初轮 / 复验	Run	`1e6e9dac` / `70f6545c`
E6 conv-30 / conv-41	Build	`5abd7718` / `e45e688e`
E11 ①	Build	`4c741582`
E11 ② / ③	Build	`5c939051`
E11 ② / ③	Run	`6aa4f580` / `1f5ad025`
E11 冻结身份 ① / ② / ③	SHA256	`c25a6ef2` / `64f69c9a` / `f7d53c5e`
E12 全量基线	Run	`a2abe1fb`
E12 补充 / 修复	Run	`df096a57` / `a9c2024b`
E24 conv-43 初次抽取	Build	`b19ae777`
E24 conv-44 初次抽取	Build	`bef9f685`
E24 conv-44 successor v3	Build	`d9fb6141`
E24 conv-44 第六份导出	文件 SHA256	`1006ce3d`
E25 实现	Git commit	`0dbd98e7`
E25 系统锁 / 计划	SHA256	`3b6e3fbc` / `5d993788`
E25 生成冻结	SHA256	`3cab5d1b`

各阶段记录所在分支的最终提交：

分支	覆盖范围	提交
`main`	E0–E5 与 M4 之前的历史	`f5a5dfd`
`codex/research-process-archive-20261103`	42 项历史探索的逐条档案，覆盖 E0–E14	`3e64811`
`codex/production-integration-20261101`	E10	`915fac0`
`codex/research-next-20261101`	E11–E19	`97bfaaa`
`codex/m5-final-input-v2-20261104`	E23	`aba95ca`
`codex/m5-final-completion-20261104`	E21	`bb9f678`
`codex/m5-final-conv44-relations-20261104`	E20、E22、E24、E25	`28ce63d`

本文图表用到的全部数字集中在 `data/metrics.json`，每条记录都标注了来源位置；图表由 `scripts/` 下的三个脚本从这份文件生成，不调用任何模型。

附录 E 实验门槛与规则清单

门槛	设定值	出现位置	实际结果
关系回放调用上限	6 次；之后另批 16 次	E1	6/6、13/16 用完后停止

门槛	设定值	出现位置	实际结果
质量增量单项上限	每项 ⩽ 16 次	E2	合计 26 次
五策略展示上限	420 次	E5	用 307 次
选择性方案节省门槛	⩾ 20%	E10	15.76%，未达标
smoke 累计上限	¥40 / 500 次 / 4 小时 / 并发 1	E11	¥21.46 / 446 次
E5 缓存应用 CPU 门槛	⩾ 15%	E14	冷启动 7.93%，未达标
E1 路由门槛	只在可证明充分时走便宜路径；规则不读取 gold	E14	覆盖 0，不放宽
canary 上限	¥25 / 8 次 / 45 分钟 / 并发 1 / 不重试	E15	8 次全部结算
Level C v1 上限	1,500 次 / USD 130.98	E22	421 次
Level C input v2 上限	1,500 次 / USD 346.98	E23	522 次
conv-44 各步恢复上限	例如 3 次 / USD 0.262，30 次 / USD 2.620	E24	每步单独批准
Level E 上限	6,000 次 / USD 1,387.93	E25	2,112 次
读取 gold 的前提	生成全部冻结，且根代理与非作者终态审计都通过	E22–E25	全部满足
晋级 Level D 的前提	单模块有独立事实增益、没有严重人物/事件/时间错误、预算获批	E20	没有模块满足
留出集曝光后	不再调参；任何重跑只能称为回归	E25	没有重跑

附录 F 未测量项

以下指标在本文范围内没有测量，或只在很小的样本上测量过。正文中没有出现以这些指标为依据的结论。

项目	状态
实际账户账单	未读取；全部费用为预约或峰价折算
人工或教师语义真值	无；所有语义判断都来自 AI 审阅
审阅者之间的一致性（kappa 等）	未计算；每项通常只有一名审阅者，E16 双审的事实粒度不同
757 题原子事实召回与保留	未测量
题内有效证据选择准确率	只有 E21 的 25 道可评分题（历史预测）
SUPERSEDE、CONFLICT 关系的判断质量	参考样本中出现 0 次，无法评估
Dynamic 删去的来源是否确实不适用	未测量
E6-A、E7、D1、CE 重排的真实答案质量	都只有离线结果或 2 道 canary 题
Hindsight 在真实模型下的抽取质量与 Build 总成本	未测量
教师隐藏评分集上的成绩	不适用；本文只有本地留出集结果
“全链路关闭 thinking” 的成绩	不存在；开发集 Build 的关系判断使用 high thinking
GPU、分组 CPU/RSS、本地硬件的货币成本	未测量

图表目录

编号	内容	位置
图 1	实验总时间线	1.3
图 2	系统流水线与失败点	2.1
图 3	实验谱系	5.1
图 4	各阶段 H/D 的 QA F1	5.2
图 5	逐题配对：提升 / 退化 / 不变	5.2
图 6	配对差值森林图	5.2
图 7	运行成功率与完整分母	5.3
图 8	失败类型构成	5.3
图 9	E25 来源覆盖漏斗	5.4
图 10	E16 证据损失归因	E16
图 11	查询成本	5.3、附录 C
图 12	单题延迟	5.3
图 13	E7–E9 迭代比较	E9
图 14	预算递进与 Dynamic 成功率	5.3
图 15	留出集构建与恢复路径	E24
图 16	候选的最终去向	5.5
补充图 S1	E5 五策略展示	E5
补充图 S2	E25 来源盲审	E25
补充图 S3	E15 E7 来源命中	E15
补充图 S4	E18 CE 重排的类别差异	E18

附录 D：2026-11-09 证据损失诊断与边界回归

D.1–D.3 为只读回放已曝光的 Level E，不新增模型调用、不重建 Build、不更新 E0–E25 成绩。D.4 另列之后获授权的真实调用回归。新的工程回归不属于独立留出评测。完整记录与复现命令、机器审计和时间解析对比分别保存。

D.1 主要损失发生在哪一步

400 条 Dynamic 记录的完整解析输入预算审计均在上限内，没有候选裁剪。399 题标注来源可评分、389 题执行成功。107 题从解析输入到有效集合失去至少一个标注 Source Turn；只有 2 题在 Answer 预算阶段进一步失去标注来源。12 题存在 Memory 预算截断，但多个 Memory 共享来源，因此不等于 12 题都失去来源。

这支持优先检查 Resolver input → Effective，而非先增加候选或 Answer 预算。它不能证明 107 题全部误删。20 个分层案例的完整 Memory、来源、阶段记录、模型排除理由和已有答案已保留，独立人工适用性核查待完成。

例如，Tim 的写作进展 Memory 被以 “不属于写作类型” 排除，但同轮原文提到 fantasy novel，最终答案仍保留小说；这是来源 Recall 下降但答案未必受损的例子。另一题问题问 Tim 的学习动力，标注来源却谈 John，排除该来源可能合理。跨证据旅行频率比较、菜肴偏好推断、照片地点与图片描述等，则需要继续核对联合支持与缺失信息。

D.2 修复与验证边界

代码修复了 before/after/since 等直接修饰日期时被压成点查询的问题，支持明确月份区间，并让 Dynamic 和 Hybrid 的 Answer 获得区间；不支持的混合范围保留未知。固定 21 个解析边界从旧代码 11/21 变为 21/21，仅表示解析契约改善。

新 Build 可显式设置 context_turns=1–3，默认仍为零。窗口只补同会话邻近原文，每条新 Memory 必须引用目标轮次，也可引用上下文支持指代。该选项有独立指纹和重试身份，不迁移冻结 Build。受控 API 测试能证明交付和引用约束，不能证明真实模型已正确消解代词或完成实体归并。

报告时间与事件/有效时间分开说明；迟报证据不因晚于世界状态查询日期而被硬删除。完整知识截止查询、实体别名机制及引用语义支持准确率仍未完成。

D.3 候选增加与最终交付

固定既有解析决策的前缀回放中，K=5→60 的已观察候选来源覆盖为 0.610→0.785，固定决策交付覆盖为 0.429→0.536。分母均为 399 题，候选使用失败项仍观察到的记录，交付对失败记零。该回放没有重新排序、解析或生成，不能作为真实 K 消融、噪声事实比例或答案 F1 的估计。

本轮没有足够证据支持全局放宽筛选或切换默认策略。独立人工语义核查仍待完成；后续真实模型小回归见 D.4。引用 ID 合法和来源覆盖不能代替语义核查。

D.4 真实模型小回归：没有整体收益证据

在免费诊断之后，用户授权最多 64 次实际请求、保守预约 USD15，并自行填写人工核查表。协议、逐题答案与完整工件独立归档，不更新 E0–E25 成绩。

设计：12 道已曝光时间题（10 普通、2 类别 5）固定相同 initial/expanded/relations/sources，使用真实 QueryService 执行新旧解析与回答，不重跑 Query Analysis/Dense。基线源码 d3c4ae1、候选 b3c9d0f；实际运行器 3be7910。另有 conv-42 六组单轮 vs 同会话 ±1 轮抽取探针，并非 fragment_turns=20 全 Build 评测。模型 deepseek-flash，temperature 0、thinking disabled、重试零。

指标	基线	候选
Query 成功 / 全部 12 题	11/12	11/12
普通题 F1，失败记零，10 题	0.517381	0.456314
普通题 EM，10 题	0.100000	0.200000
共同成功普通题 F1，8 题	0.563393	0.445393
类别 5 字面拒答	2/2	2/2

普通题改善 2、退化 3、持平 5，配对差 −0.061067，探索性 95% bootstrap 区间 [−0.313876, +0.233333]。两次解析失败分别发生于候选和基线，完整保留；共同成功子集同样下降。预选小样本与固定检索不支持整体收益或泛化结论。

分数与事实需要分开：一题候选拒绝将露营计划视作已完成，F1 因此下降；另一题较长答案扣短答分，但两臂均把 Saturday after October 28, 2023 解释为 October 28 当天，严格之后应为 November 4。Gold 只有 Go hiking，无法测出日期错位；AI 审阅也漏检。Monday before July 24 同样出现当天错位，原文报告与题目之间可能存在时间不一致，留给真人核查。

实体和引用：六组新抽取均未重现 Joanna 饲养乌龟，不能据此称历史错误已修复。两组候选从空抽取恢复态度/知识事实，命名 Nate，却只引用目标轮的 your turtles，没有引用支撑指代的邻轮。窗口联合原文支持不代表单条 Memory 的引用足够；不据此启用默认上下文或全量重建。

审阅与费用：四批 AI 审阅隐藏臂标签但保留可能提示身份的时间结构，仅两批通过，覆盖 9/18 对；失败批保持 invalid_output。旧审阅校验器对零来源拒答仍强制引文，911ed2c 已离线修复，未补跑或追认为成功。AI 标签保留原样，作者指出的漏检另存；莫远序于 2026-11-09 提交 18 对核查；条件判断保留，q02 日期及主观状态口径仍待裁定；q08 两臂解释均误归属 Toby。实际 62 次请求，保守预约 USD3.5863482；已报告用量峰价上界 USD0.4074948，另一次 usage 未知仍保留完整预约，未读取账单。原工程验证见 validation；当前核查与 PDF 哈希见 human-review-provenance.json。