面向长期对话的动态记忆管理与证据问答系统

摘要：本项目实现面向长期对话的记忆管理与证据问答。系统从原始轮次抽取 Memory，在构建期维护历史关系和当前状态投影，在查询期按问题时间与状态选择有效证据。本文结合固定的 757 题四策略真实基线分析运行可靠性和查询开销，并给出默认关闭的 Temporal/Event Sidecar 候选。

1 问题与实现范围

长期对话中的人物状态会变化，历史事件也可能在当前问题中继续有效。系统需要保存事实来源及时间条件，避免只按相似度或记录新旧选择答案。当前实现使用英文检索与证据，中文界面面向课程演示。原始 QA 标注仅供评测，构建使用 conversation。

2 当前架构

Streamlit 调用 FastAPI，由业务模块访问 SQLite 与检索索引。来源身份包含 dataset、sample 和 dia_id。Memory 连接多个 SourceTurn，关系保存判断理由与双方来源，CurrentState 由历史和关系重算。完整 Build 将来源、Memory、关系、投影和索引绑定为一个版本。

Build 依次完成抽取、校验、索引、关系、投影与发布。片段任务保存成功与失败状态，显式重试复用成功产物。Query 固定一个完整版本，经问题分析、混合检索和有界历史扩展后选择有效证据。查询补判留在本次 Trace。

时间语义分别保留会话锚点与事件时间。当前问题采用所选对话的证据截止时间，显式日期查询采用对应历史条件。SUPERSEDE 替代当前状态的旧取值，旧证据继续支持历史查询。CONFLICT 保留相同适用条件下尚待消解的矛盾。

3 实验设计与来源

研究来源提交：f41c94b79d0d59a81a1a26ac343ac82420560898。原 Run：a2abe1fb49be45ccba291728e1f6b3c9。聚合入口为 docs/team-v2/research-evidence.json。开发对话固定为 conv-26、conv-30、conv-41、conv-42。757 QA 分别执行 Full Text、Vector、Hybrid 和 Dynamic，共 3,028 项，其中 2,969 项成功、56 项失败、3 项 unknown。

Full Text 使用完整原始对话，Vector 使用 Dense 检索，Hybrid 使用混合检索与扩展，Dynamic 增加有效证据解析。

4 结果与完整分母

表 1 四种策略的问答结果与技术成功率

策略	计划	成功	失败	unknown	成功子集 QA	技术成功率
Full Text	757	756	0	1	0.465484	99.87%
Vector	757	751	5	1	0.523866	99.21%
Hybrid	757	753	3	1	0.524659	99.47%
Dynamic	757	709	48	0	0.550008	93.66%

在双方成功的 705 对上，Dynamic QA 为 0.550374，Hybrid 为 0.524300，均差 +0.026074。Dynamic 在此集合胜 136 项、负 110 项、平 459 项。

Dynamic 完整分母 QA 为 0.515133，计算时 48 个技术失败记零。Hybrid 的 3 个失败记零，将 1 个 unknown 分别按 0 和 1 计分，完整分母得分范围为 [0.521886, 0.523207]。Dynamic 在成功配对中得分较高，但纳入技术失败后，完整分母得分低于 Hybrid 的下界。

5 成本与未知开销

按冻结峰值价估算，Dynamic 已知查询费用为 98.930522 CNY，Hybrid 为 9.597679 CNY，前者约为后者的 10.31 倍。Dynamic 的 Resolution 费用为 96.285551 CNY，占其已知查询估算的 97.33%。

共享 Build 已知估算为 89.655017 CNY，另有 7.077888 CNY 未知预留。Hybrid 查询另有 2.359296 CNY 未知预留。Full Text 与 Vector 也包含未知请求，预留金额与已知估算分开计算。

6 失败分析与负结果

conv-30 的原四策略组合中有 374 项成功、43 项失败和 3 项 unknown，是后续逐项排查的重点。当前评估尚缺独立人工语义标签，引用语义正确性与严重错误率仍待评测。

E1 Router v1 的 LOCO 历史模拟在 757 项中全部选择 Dynamic，配对增益为 0。E5 在隔离的固定索引编码与内存排序基准中，冷编码 CPU 下降 64.22%，本地检索 CPU 下降 57.36%。这两项改善发生在本地计算阶段，provider token 和 CNY 节省均为 0，端到端收益仍待评估。

7 Product Console 与 Sidecar 诊断候选

Product Console（提交 7a159d7）提供 Overview、Memory、Query/Evidence、Experiments 与 Demo 导航。Overview 展示所选 Build 身份，Memory 支持只读记录检查，Evidence 读取已保存 Trace。冻结实验报告使用独立原 Run 身份。新的 Timeline 与来源跳转仍在任务 #27 中推进，现有五阶段工作流可用于原文核查。

Temporal/Event Sidecar（提交 0f470a3）作为独立诊断组件运行，默认关闭，使用 diagnostic_only 模式。输入绑定 Build fingerprint、Memory 与来源 ID；reported_at 表达陈述时间，event_time 表达事件时间。规则为英文显式模式提供有限推断，歧义保留 unknown，计划和否定沿用对应状态。

Sidecar 的六个测试文件共 145 项通过。16 个合成案例包含 15 个有效对照，另有 1 个重复 ID 输入按契约拒绝。输入内容、来源引用与 off/on/off 回滚响应保持一致。两个合成完整 Build 通过兼容检查，诊断前后的数据库及导出摘要相同。结果支持候选的隔离性与回滚能力，生产接入及真实 QA 效果仍待验证。

8 离线复现与演示

依赖由 uv.lock 锁定，演示入口为 tools/team_v2/demo.py。执行 prepare 创建合成数据后，分别启动 api 和 ui，具体命令与版本信息见包内 REPRODUCE.md。

演示通过保存的 Trace 回放当前住所、历史住所、冲突出生年份和证据不足四种情况，视频标明 OFFLINE REPLAY。合成案例用于检查应用行为，第 4 节的模型效果来自独立的真实基线实验。

9 来源索引

论断与统计字段见 claims-ledger.json。表格对应研究聚合的 /original_baseline/groups/strategy，配对结果见 /paired，成本见 /provider_cost_estimates 和 /shared_build_cost。研究文件的摘要校验值保存在 source_hashes。

[1] 仓库：https://github.com/kenqia/locomo-dynamic-memory

[2] Console 候选：https://github.com/kenqia/locomo-dynamic-memory/pull/39

[3] Sidecar 候选：https://github.com/kenqia/locomo-dynamic-memory/pull/38