软件需求工程课程项目

动态对话记忆管理

系统实现与实验评估

基于冻结实验选择默认策略，以来源和版本核查系统行为

第三组 在阴雨天游泳

2026 年 11 月 8 日

同一人物的历史事实，需要按问题时间选择

相关性检索得到候选证据，时间与状态决定其适用条件。

事实如何变化

早期记录：Alex 住在 Paris。
后续陈述：Alex 从 Paris 搬到 Rome。

系统如何保留依据

Memory 关联 SourceTurn，保留原文与时间。
当前状态更新后，历史证据继续可查。

当前问题采用 Rome

历史问题按日期选择 Paris

来源：CONTEXT.md、contracts.md；住所变化为合成示例

构建期固定版本，查询期按策略组织证据

BUILD 构建与发布

来源导入 → Memory 抽取 → 结构校验 → 混合索引 → 历史关系 → 版本发布

QUERY 检索与回答

原始问题 → 问题分析 → 混合检索 → 历史扩展 → 策略选择 → 回答与引用

Hybrid 默认直接回答，Dynamic 显式增加有效证据解析

来源：main 0ebb2b8，RELEASE_COMPONENT_MATRIX.md、DEFAULTS_AND_ROLLBACK.md

当前状态更新后，历史证据仍然可用

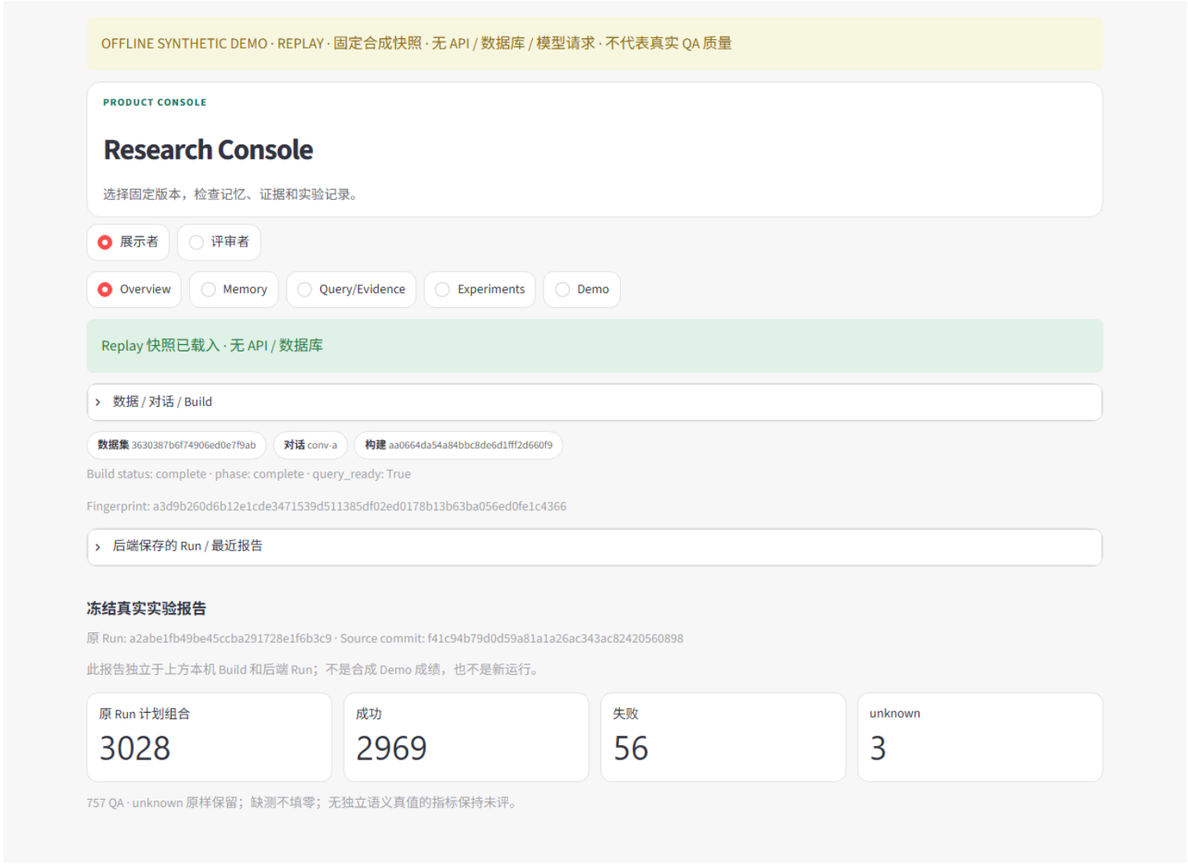
以下四种合成情况用于检查时间选择与回答状态。

问题条件	对应证据	输出
当前住所	Alex 从 Paris 搬到 Rome	Rome
2023-05-01 住所	早期住所记录及原文	Paris
Sam 出生年份	1990 与 1992 的矛盾陈述	CONFLICT，保留双方来源
Alex 护照号码	来源缺少对应信息	INSUFFICIENT

SUPERSEDE 更新当前取值，旧证据支持历史日期查询

来源：demo-manifest.json、CONTEXT.md

新版 Console 支持版本检查与六类合成回放



只读控制台

Timeline 与完整来源跳转。
Trace 分为四个证据阶段，
错误与预算保留在对应阶段。

无数据库 Replay

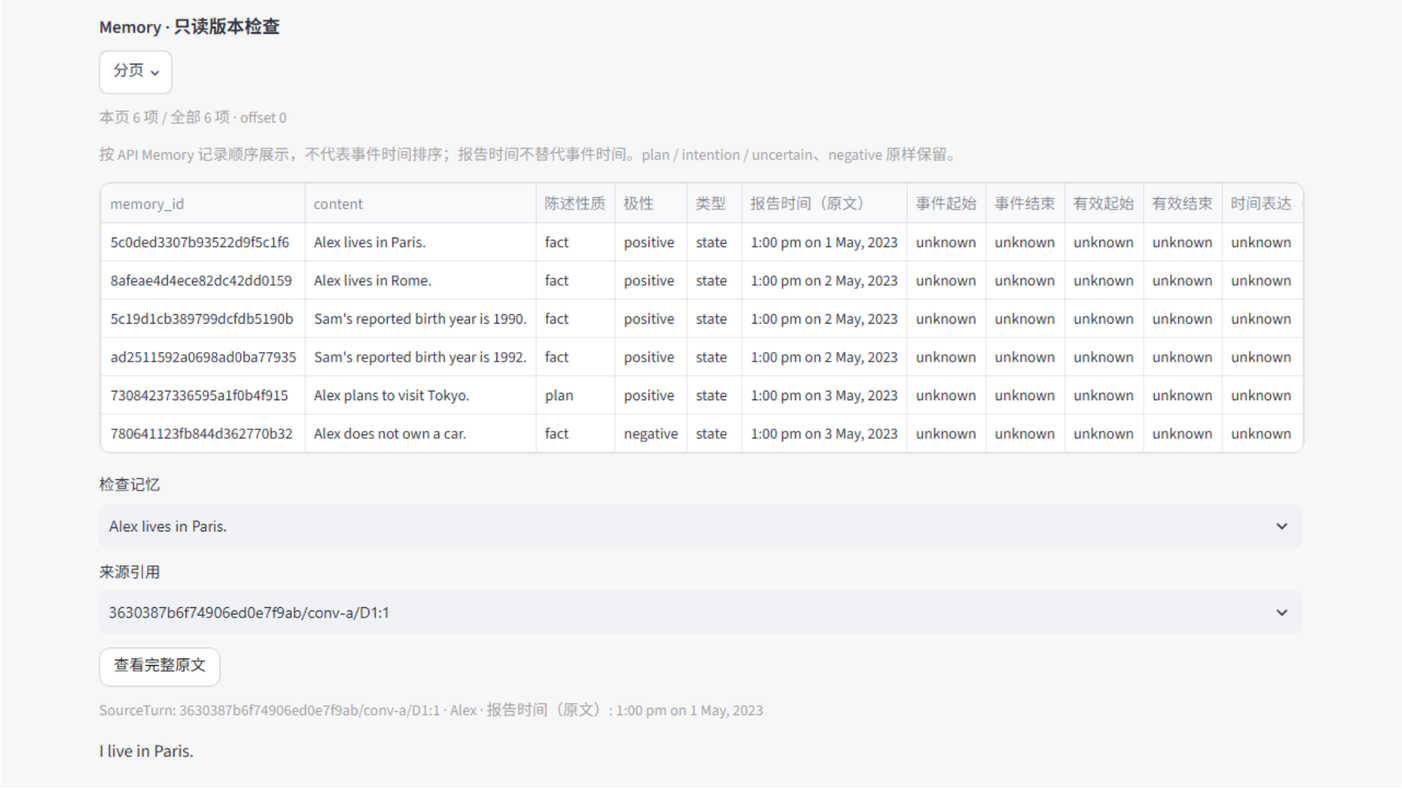
三个 JSON 经过摘要校验，
支持两个 Build 和六个案例。
运行时使用离线合成快照。

截图来自 11 月 6 日仓库素材

来源：Product Console 44d20dc，product-followup-validation.md、replay-overview.png

从 Memory 选择引用，直接检查完整原文

Memory 与来源检查局部截图，保留计划、否定与 unknown。



Memory · 只读版本检查

分页

本页 6 项 / 全部 6 项 · offset 0

按 API Memory 记录顺序展示，不代表事件时间排序；报告时间不替代事件时间。plan / intention / uncertain、negative 原样保留。

memory_id	content	陈述性质	极性	类型	报告时间（原文）	事件起始	事件结束	有效起始	有效结束	时间表达
5c0ded3307b93522d9f5c1f6	Alex lives in Paris.	fact	positive	state	1:00 pm on 1 May, 2023	unknown	unknown	unknown	unknown	unknown
8afeae4d4ece82dc42dd0159	Alex lives in Rome.	fact	positive	state	1:00 pm on 2 May, 2023	unknown	unknown	unknown	unknown	unknown
5c19d1cb389799dcfdb5190b	Sam's reported birth year is 1990.	fact	positive	state	1:00 pm on 2 May, 2023	unknown	unknown	unknown	unknown	unknown
ad2511592a0698ad0ba77935	Sam's reported birth year is 1992.	fact	positive	state	1:00 pm on 2 May, 2023	unknown	unknown	unknown	unknown	unknown
73084237336595a1f0b4f915	Alex plans to visit Tokyo.	plan	positive	state	1:00 pm on 3 May, 2023	unknown	unknown	unknown	unknown	unknown
780641123fb844d362770b32	Alex does not own a car.	fact	negative	state	1:00 pm on 3 May, 2023	unknown	unknown	unknown	unknown	unknown

检查记忆

Alex lives in Paris.

来源引用

3630387b6f74906ed0e7f9ab/conv-a/D1:1

查看完整原文

SourceTurn: 3630387b6f74906ed0e7f9ab/conv-a/D1:1 · Alex · 报告时间（原文）: 1:00 pm on 1 May, 2023

I live in Paris.

时间与状态分开核查

报告、事件及有效时间分列。
列表沿用 API 记录顺序。

证据阶段可逐项检查

初始与扩展候选分别展示，
有效证据和最终引用可回溯
到同一 Build 的来源。

来源：Product Console 44d20dc，replay-memory-source.png；Synthetic Replay，局部视图

历史基线、开发调整和留出验证分别报告

757

历史四策略 QA

100

同一开发样本

400

本地留出样本

实验层次	比较范围	统计条件
历史基线	757 题，四策略	原 Run，成功子集与完整分母分列
Level C v1	100 题，Hybrid / Dynamic	80 普通题 + 20 诊断题
input v2	同一开发 100 题	输入与思考配置同时调整
Level E	conv-43 / conv-44，400 题双臂	类别 1–4 与类别 5 分列，Bonus 关闭

Level E 使用冻结配置；后续在该数据上的修复与重跑按回归报告。

来源：main 0ebb2b8，PERSONAL_EXPERIMENT_SUMMARY.md、Level E official-scores.json

Dynamic 的子集得分较高，运行成功率较低

策略	技术成功	失败	unknown	成功子集 QA	技术成功率
Full Text	756 / 757	0	1	0.465484	99.87%
Vector	751 / 757	5	1	0.523866	99.21%
Hybrid	753 / 757	3	1	0.524659	99.47%
Dynamic	**709 / 757**	**48**	**0**	**0.550008**	**93.66%**

完整运行比较需同时考虑 QA 得分与技术失败

历史 705 对均差 +0.026074；完整 757 分母下，Dynamic 低于 Hybrid 下界。

来源：冻结历史 Run a2abe1fb49be45ccba291728e1f6b3c9；成功子集 QA，完整分母另见报告

留出实验点估计略升，95% 区间跨零

+0.006545

Level E 类别 1–4：Dynamic − Hybrid F1

95% 配对区间

[−0.020133, +0.034035]

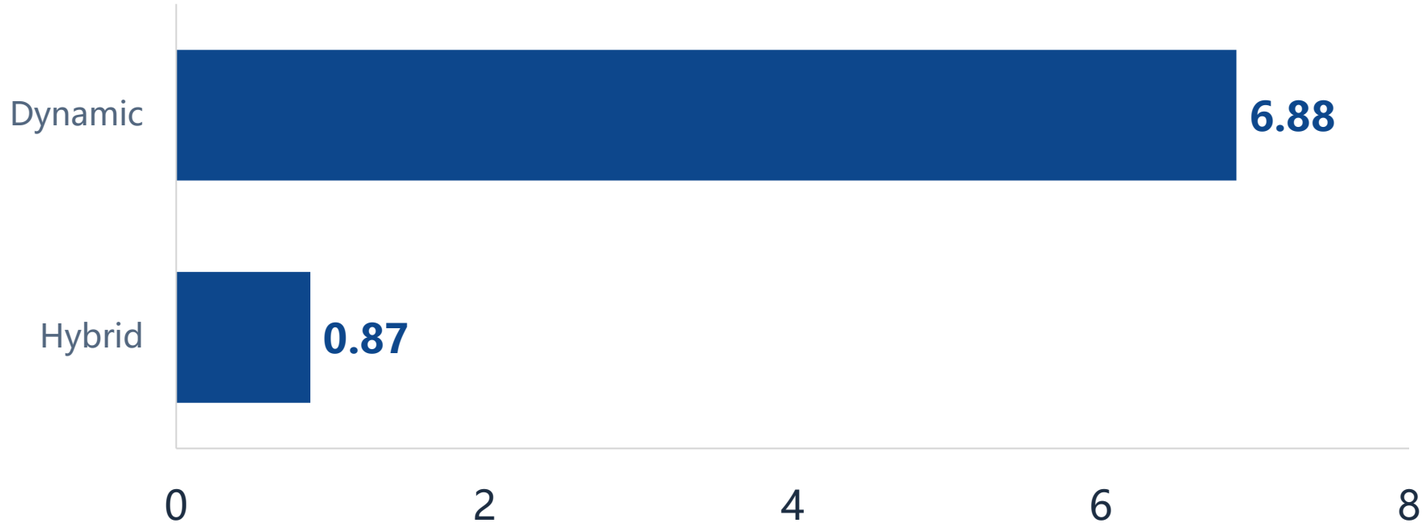
完整分母口径	Hybrid	Dynamic
开发 input v2 普通题 F1（80）	0.401172	0.444702
Level E 类别 1–4 F1（301）	**0.402606**	**0.409151**
Level E 类别 5 字面拒答（99）	0.858586	0.808081
Level E 技术成功（400）	394 / 400	389 / 400

失败记零。置信区间按题重采样，只反映两段留出对话内的变化。

来源：main 0ebb2b8，official-scores.json /category_metrics；PERSONAL_EXPERIMENT_SUMMARY.md

Dynamic 已报 usage 查询峰价金额约为 Hybrid 的 7.90 倍

Level E，单位 USD；金额为用量估算，实际账单另行核对。



7.90 倍

Dynamic / Hybrid 查询估算

p50：Hybrid / Dynamic（秒）

2.370 / 8.315

18 次缺失 usage 的请求保留预约 USD 0.9522705

共享 Build 已知峰价 USD 6.6141915；独立部署每臂承担完整 Build。

来源：main 0ebb2b8，LEVEL_E_RESULTS_V1.md；估算金额与预算预约分开记录

技术失败与来源语义支持分开评估

394 / 400

Hybrid 技术成功

389 / 400

Dynamic 技术成功

复查对象	已记录结果	解释范围
运行失败	8 invalid_output + 9 HTTP 402 项	格式失败与余额拒绝分别定位
原文支持	Hybrid 250/343；Dynamic 233/307	按可判定审阅单元统计
引用支持	Hybrid 195/321；Dynamic 197/310	合法引用 ID 与语义支持分别检查

来源审阅尚未提供 Dynamic 稳定改善质量的证据

800 项由非作者 AI 每项一次标注，作为诊断参考；人工与教师真值另行核查。

来源：main 0ebb2b8，source-review-summary.json、source-review-paired.json、official-scores.json

工程能力与实验收益分别决定扩展功能的采用

研究扩展	已有能力或离线结果	当前采用
历史关系 / 版本	保留状态演化及来源	核心保留，只读检查
Graph 浏览 / 两跳	来源覆盖略升，最终交付无增益	浏览可选，两跳默认关闭
Compression	可逆分组；完整 messages 代理仅省 0.02925%	wire 默认关闭
Adaptive / Temporal	未形成总体交付来源代理收益	新增机制默认关闭

公共默认链保持 Hybrid，研究选项通过显式入口运行

来源：main 0ebb2b8，RELEASE_COMPONENT_MATRIX.md、PERSONAL_EXPERIMENT_SUMMARY.md

真实句式适配不足，Sidecar 暂缓接入主链

两个已曝光的真实开发 Build，只读诊断，新增 Provider 请求为 0。

503

真实 Memory

63,057

完整候选关系对

0 / 68

信息性正确覆盖

主要瓶颈

502 条超出当前断言语法范围，
1 条缺少匹配来源。
时间与事件关系判断均为 unknown。

参考与输出

40 Memory + 20 关系 + 8 问题。
每单元一份非作者 AI 参考。
8 个状态问题均输出 insufficient。

采用建议：默认关闭，先验证真实句式覆盖与来源绑定

本轮是诊断研究，控制为 baseline_fields，尚未形成新的 QA 干预结果。

来源：Sidecar 2deefd5，REPORT.md、run-v2-summary.json、run-v2-analysis.json

核心已合入 main，产品与诊断分支分别核验

交付部分	当前证据	集成与验收状态
公共核心 main	967 passed / 28 deselected	PR #40 已合并，公共默认 Hybrid
Product Console	25 定向；Linux 599 passed / 6 deselected	44d20dc 独立分支，集成待核验
Sidecar 研究	174 专项；两真实 Build 完整诊断	2deefd5 独立分支，建议暂缓接入
研究交付	PPTX/PDF、技术报告与新版视频	本地生成；真实成员验收另行完成

不同分支的测试记录保留各自版本与排除范围

来源：PUBLIC_SNAPSHOT_VALIDATION.json；Product followup-validation；Sidecar REPORT.md

默认采用 Hybrid，Dynamic 保留显式研究入口

实验结论 **留出质量差值区间跨零，Dynamic 增加费用与延迟。**

后续工作	可检查的完成依据
跨分支集成	Console 与 main 的版本、来源及 Trace 端到端核验
证据语义复核	由真实成员检查答案与引用，保留分歧及失败
解析成本优化	冻结触发条件与输入预算，在独立方案中比较质量和开销
Sidecar 下一候选	先证明真实句式适配，再评估问答干预价值

以完整分母、来源支持和资源代价共同判断方案取舍。

来源：main 0ebb2b8 DEFAULTS_AND_ROLLBACK.md；Sidecar 2deefd5 ADR-RECOMMENDATION.md